Matheus Sanchez Duda

Classificação de imagens em múltiplos benchmarks de visão computacional: um estudo comparativo entre CNNs clássicas e arquiteturas híbridas quântico-clássicas

São Paulo
2026

Matheus Sanchez Duda

Classificação de imagens em múltiplos benchmarks de visão computacional: um estudo comparativo entre CNNs clássicas e arquiteturas híbridas quântico-clássicas

Trabalho de Conclusão de Curso II apresentado ao SENAC Santo Amaro como requisito parcial para conclusão do curso de Ciência da Computação.

SENAC – Serviço Nacional de Aprendizagem Comercial
Unidade Santo Amaro
Bacharelado em Ciência da Computação

Orientador: Prof. Jorge Echeimberg
Coorientador: Prof. Thyago Quintas

São Paulo
2026

Resumo

Este trabalho tem como objetivo investigar e comparar de forma sistemática o desempenho de redes neurais convolucionais (CNNs) clássicas e arquiteturas híbridas quântico-clássicas aplicadas à tarefa de classificação supervisionada de imagens em nove conjuntos de dados públicos de visão computacional (MNIST, Fashion-MNIST, KMNIST, EMNIST, CIFAR-10, CIFAR-100, SVHN, GTSRB e FER2013). A pesquisa avalia o comportamento preditivo e a eficiência computacional dos modelos frente a diferentes complexidades visuais, resoluções espaciais, números de canais e distribuições de classes, contemplando ainda análises controladas de funções de ativação, tamanhos de lote (*batch size*), estratégias de quantização e execução multiplataforma. Busca-se aprimorar a capacidade de generalização do modelo clássico de referência e superar as limitações de convergência e estabilidade de modelos quânticos variacionais simulados, viabilizando uma comparação estatística e experimental robusta entre os dois paradigmas.

Palavras-chave: visão computacional. classificação de imagens. redes neurais convolucionais. computação quântica. aprendizado de máquina quântico. modelos híbridos quântico-clássicos.

Abstract

This work aims to systematically investigate and compare the performance of classical convolutional neural networks (CNNs) and hybrid quantum-classical architectures applied to supervised image classification across nine public computer vision datasets (MNIST, Fashion-MNIST, KMNIST, EMNIST, CIFAR-10, CIFAR-100, SVHN, GTSRB, and FER2013). The research evaluates the predictive behavior and computational efficiency of the models under different visual complexities, spatial resolutions, channel counts, and class distributions, while also encompassing controlled analyses of activation functions, batch sizes, quantization strategies, and cross-platform execution. It seeks to enhance the generalization capability of the classical baseline model and overcome convergence and stability limitations of simulated variational quantum models, enabling a robust statistical and experimental comparison between both paradigms.

Keywords: computer vision. image classification. convolutional neural networks. quantum computing. quantum machine learning. hybrid quantum-classical models.

Lista de ilustrações

Figura 1 – Representação matemática de uma imagem em escala de cinza como matriz de intensidades. 20
Figura 2 – Representação esquemática das operações de convolução e *pooling* em uma rede neural convolucional. 34
Figura 3 – Exemplo de visualização de mapas de características em diferentes blocos convolucionais. As camadas iniciais tendem a preservar bordas, texturas e contornos, enquanto camadas mais profundas representam padrões mais abstratos. 36
Figura 4 – Exemplo de decomposição de uma convolução espaço-temporal em convolução espacial e temporal. No contexto deste trabalho, a figura ilustra a generalidade do operador convolucional, sendo os nove *benchmarks* avaliados compostos por imagens estáticas bidimensionais. 37

Lista de tabelas

Tabela 1 – Caracterização estrutural dos 9 conjuntos de dados utilizados no *benchmark*. 18
Tabela 2 – Cronograma de desenvolvimento do TCC. 55

Lista de Abreviaturas e Siglas

Abreviatura/Sigla	**Significado**
AUC	*Area Under the Curve* (Área sob a Curva)
CNN	*Convolutional Neural Network* (Rede Neural Convolucional)
GPU	*Graphics Processing Unit* (Unidade de Processamento Gráfico)
NISQ	*Noisy Intermediate-Scale Quantum*
PQC	*Parameterized Quantum Circuit* (Circuito Quântico Parametrizado)
QML	*Quantum Machine Learning* (Aprendizado de Máquina Quântico)
QPU	*Quantum Processing Unit* (Unidade de Processamento Quântico)
RGB	*Red, Green, Blue* (Vermelho, Verde e Azul)
ROC	*Receiver Operating Characteristic*
TCC	Trabalho de Conclusão de Curso

Sumário

1 INTRODUÇÃO 9
1.1 Contexto 9
1.2 Justificativa 10
1.3 Objetivo geral 11
1.4 Objetivos específicos 11
1.5 Hipótese 12
1.6 Delimitações do trabalho 13

2 REVISÃO BIBLIOGRÁFICA 14
2.1 Metodologia da pesquisa bibliográfica 14
2.2 Classificação de imagens e diversidade de domínios em visão computacional 15
2.2.1 Reconhecimento de dígitos, caracteres e símbolos manuscritos 15
2.2.2 Categorização de artigos de vestuário, objetos naturais e sinalização viária . 15
2.2.3 Reconhecimento de expressões faciais e desafios de variabilidade intraclasse 16
2.3 Bases de dados e benchmarks utilizados no estudo 16
2.3.1 Importância da avaliação multi-dataset em aprendizado profundo e quântico 17
2.3.2 Caracterização dos 9 conjuntos de dados do benchmark 17
2.3.3 Qualidade dos rótulos, desbalanceamento e heterogeneidade entre domínios 19
2.4 Imagens digitais e classificação computacional 19
2.4.1 Representação computacional de imagens digitais 19
2.4.2 Classificação supervisionada de imagens 22
2.4.3 Treinamento, validação, teste e generalização 24
2.4.4 Métricas de avaliação 26
2.4.5 Seleção de métricas em benchmarks multiclasse e desbalanceados 29
2.5 Redes neurais e aprendizado profundo 30
2.5.1 Redes neurais artificiais 31
2.5.2 Redes neurais convolucionais 32
2.5.3 CNNs aplicadas a múltiplos domínios de visão computacional e eficiência de execução 37
2.5.4 Aumento de dados, regularização e overfitting 38
2.5.5 Explicabilidade e interpretação de representações em CNNs 40
2.6 Computação quântica e aprendizado de máquina quântico 40
2.6.1 Qubits, superposição, emaranhamento e medição 41
2.6.2 Portas e circuitos quânticos parametrizados 42

2.6.3 Codificação de dados clássicos em estados quânticos . . . 43
2.6.4 Modelos variacionais quânticos . . . 44
2.6.5 Limitações de simulação, barren plateaus e escalabilidade . . . 45
2.7 Modelos híbridos quântico-clássicos . . . 46
2.7.1 Modelos híbridos quântico-clássicos para classificação . . . 47
2.7.2 Integração entre CNNs e circuitos quânticos . . . 48
2.7.3 Limitações práticas de dimensionalidade e custo de simulação em visão computacional . . . 49
2.8 Trabalhos correlatos . . . 49
2.8.1 Benchmarks em visão computacional e avaliação multi-dataset . . . 49
2.8.2 Aprendizado profundo, hiperparâmetros e eficiência computacional . . . 50
2.8.3 Computação quântica e modelos híbridos aplicados à classificação de imagens 50
2.9 Síntese da lacuna de pesquisa . . . 51

3 DESENVOLVIMENTO . . . 52
3.1 Solução proposta . . . 52
3.2 Tipo de pesquisa . . . 54
3.3 Visão geral da solução proposta . . . 54
3.4 Bases de dados e definição das classes . . . 54
3.5 Pré-processamento e preparação dos dados . . . 54
3.6 Modelo clássico de referência . . . 54
3.7 Modelo híbrido quântico-clássico . . . 54
3.8 Diagnóstico e evolução do modelo quântico . . . 54
3.9 Protocolo experimental . . . 54
3.9.1 Configuração dos experimentos . . . 54
3.9.2 Controle de variáveis . . . 54
3.9.3 Ambiente computacional (Windows e macOS) . . . 54
3.9.4 Reprodutibilidade . . . 54
3.10 Métricas de avaliação . . . 54
3.11 Critérios de validação . . . 54
3.12 Riscos e limitações . . . 54
3.13 Cronograma . . . 54

REFERÊNCIAS . . . 56

1 Introdução

O avanço da Inteligência Artificial e do Aprendizado Profundo (*Deep Learning*) consolidou novos padrões de desempenho em tarefas complexas de reconhecimento de padrões e visão computacional. Entre essas aplicações, a classificação supervisionada de imagens destaca-se como um problema fundamental, abrangendo desde o reconhecimento de caracteres manuscritos e símbolos tipográficos até a categorização de objetos naturais, sinais de trânsito e expressões faciais em condições variadas de iluminação e resolução.

As redes neurais convolucionais (CNNs) estabeleceram-se como uma das principais abordagens para tarefas visuais devido à sua capacidade de extrair representações hierárquicas diretamente a partir da estrutura espacial dos pixels. No entanto, o desempenho e o custo operacional dessas arquiteturas permanecem sensíveis a escolhas metodológicas e de engenharia, tais como a função de ativação empregada, o tamanho do lote de treinamento (*batch size*), o grau de desbalanceamento entre classes, a aplicação de técnicas de quantização e as características de hardware do ambiente de execução.

Paralelamente, a computação quântica e o Aprendizado de Máquina Quântico (*Quantum Machine Learning* – QML) têm despertado crescente interesse científico como paradigmas emergentes de processamento da informação. Modelos híbridos quântico-clássicos propõem a integração entre extratores clássicos de características e circuitos quânticos parametrizados (PQCs), buscando explorar propriedades como superposição e emaranhamento em espaços de Hilbert de alta dimensão. Contudo, sua aplicação prática em problemas de visão computacional ainda enfrenta gargalos severos de simulação clássica, compressão dimensional, estabilidade de gradientes e escalabilidade em múltiplos domínios.

Diante desse cenário, este trabalho propõe um estudo experimental comparativo entre arquiteturas clássicas baseadas em redes neurais convolucionais e arquiteturas híbridas quântico-clássicas avaliadas sobre nove conjuntos de dados de visão computacional. A pesquisa investiga não apenas o desempenho preditivo global e por classe (Macro-F1, acurácia, precisão, revocação e matrizes de confusão), mas também a telemetria de treinamento, o impacto de hiperparâmetros e a viabilidade prática das abordagens em um protocolo experimental estritamente controlado e reprodutível.

Assim, este capítulo apresenta o contexto da pesquisa, a justificativa, os objetivos geral e específicos, a hipótese científica e as delimitações do trabalho.

1.1 Contexto

A classificação automática de imagens é um dos pilares da visão computacional moderna, servindo de base para sistemas autônomos, leitura óptica de documentos, inspeção

industrial, segurança viária e interação humano-computador. Ao longo da última década, a disponibilidade de *benchmarks* públicos padronizados permitiu avaliar a evolução de algoritmos sob diferentes níveis de dificuldade visual.

Conjuntos de dados em escala de cinza centrados em formas estruturadas — como dígitos manuscritos (MNIST), caracteres cursivos japoneses Kuzushiji (KMNIST), letras e dígitos estendidos (EMNIST) e artigos de vestuário (Fashion-MNIST) — oferecem cenários controlados para testar a capacidade de extração de contornos e topologias locais. Por outro lado, bases de imagens naturais e cenários reais — como objetos cotidianos em baixa resolução (CIFAR-10 e CIFAR-100), dígitos em fachadas urbanas (SVHN), placas de trânsito sob variações climáticas e de perspectiva (GTSRB) e expressões faciais humanas (FER2013) — impõem desafios substancialmente maiores, incluindo ruído de fundo, múltiplos canais de cor, variações de contraste e forte desbalanceamento entre categorias.

Nesse contexto, as redes neurais convolucionais destacam-se pela eficiência na extração automática de atributos espaciais por meio de filtros treináveis. Todavia, a busca por representações mais compactas e expressivas motivou a investigação de arquiteturas híbridas quântico-clássicas. Nesses modelos, camadas convolucionais clássicas atuam na redução da dimensionalidade espacial da imagem original para um vetor latente compacto, o qual é codificado em estados quânticos e processado por um circuito quântico variacional antes da camada de decisão final.

Entretanto, grande parte da literatura em Aprendizado de Máquina Quântico restringe seus experimentos a um único conjunto de dados simplificado — frequentemente subconjuntos binários do MNIST —, dificultando a compreensão de como essas arquiteturas se comportam quando submetidas a múltiplos domínios visuais, maior número de classes e variações sistemáticas de hiperparâmetros. Este trabalho insere-se exatamente nessa interseção entre visão computacional, engenharia de aprendizado profundo e aprendizado de máquina quântico, propondo um *benchmark* consolidado em nove bases de dados para avaliar o comportamento real, os limites computacionais e a competitividade prática dos modelos clássicos e híbridos.

1.2 Justificativa

A justificativa deste trabalho estrutura-se em três dimensões complementares: tecnológica, acadêmica e metodológica.

Na dimensão tecnológica e prática, o treinamento e a inferência de modelos de visão computacional exigem um equilíbrio rigoroso entre qualidade preditiva (medida por métricas como Macro-F1) e eficiência computacional (tempo por época, *throughput*, latência e consumo de memória de vídeo e sistema). Compreender como escolhas de funções de ativação, dimensionamento de lotes (*batch sizes*), quantização pós-treinamento e arquiteturas

de hardware (como estações Windows com GPUs dedicadas e sistemas Apple Silicon com memória unificada) afetam o desempenho em múltiplos domínios visuais fornece subsídios diretos para o projeto de sistemas eficientes de aprendizado de máquina.

Na dimensão acadêmica, embora o aprendizado profundo clássico esteja amplamente consolidado (LECUN; BENGIO; HINTON, 2015), a integração de circuitos quânticos variacionais em *pipelines* de visão computacional ainda carece de validação comparativa abrangente (CEREZO et al., 2021; LONG et al., 2025). Investigar se a substituição ou complementação de camadas densas por cabeças híbridas quânticas traz ganhos ou perdas mensuráveis sob condições idênticas de pré-processamento contribui para separar expectativas teóricas da realidade experimental na era NISQ (*Noisy Intermediate-Scale Quantum*).

Por fim, na dimensão metodológica e científica, observa-se uma lacuna importante na reprodutibilidade de estudos comparativos entre modelos clássicos e quânticos. Muitos trabalhos avaliam arquiteturas em cenários isolados, sem controle estrito de sementes aleatórias, sem varredura sistemática de hiperparâmetros e sem análise detalhada de resíduos e telemetria. Ao estabelecer uma campanha experimental padronizada sobre nove *datasets* distintos, este TCC oferece uma base empírica sólida, auditável e reprodutível para a avaliação de modelos clássicos e híbridos.

1.3 Objetivo geral

Investigar e comparar sistematicamente o desempenho preditivo, a estabilidade de convergência e o custo computacional de redes neurais convolucionais (CNNs) clássicas e arquiteturas híbridas quântico-clássicas na classificação supervisionada de imagens ao longo de nove conjuntos de dados de visão computacional, avaliando o impacto de funções de ativação, tamanhos de lote, quantização e ambientes de execução.

1.4 Objetivos específicos

1. Estruturar e inventariar um conjunto padronizado de nove bases de dados públicas de visão computacional (MNIST, Fashion-MNIST, KMNIST, EMNIST, CIFAR-10, CIFAR-100, SVHN, GTSRB e FER2013), caracterizando suas resoluções, canais e distribuições de classes;

2. Implementar um *pipeline* experimental reprodutível de pré-processamento, divisão estratificada de dados, aumento de dados (*data augmentation*) controlado, treinamento, validação e teste;

3. Desenvolver e otimizar uma arquitetura de CNN clássica de referência, avaliando o impacto de diferentes funções de ativação, tamanhos de lote (*batch sweep*) e estratégias de quantização;

4. Projetar uma arquitetura híbrida quântico-clássica compatível com as restrições atuais de simulação de circuitos quânticos parametrizados;

5. Investigar configurações do componente quântico, incluindo número de qubits, estratégia de codificação de atributos (*embedding*), topologia do *ansatz* variacional e integração com camadas clássicas;

6. Comparar o desempenho dos modelos utilizando métricas globais e por classe, tais como acurácia, precisão, revocação (*recall*), Macro-F1, curvas de validação e matrizes de confusão;

7. Analisar a telemetria de execução, contemplando tempo por época, tempo acumulado de campanha, *speedup* entre plataformas (Windows e macOS), *throughput* e latência em cenários quantizados;

8. Discutir criticamente a paridade de resultados, as vantagens, as limitações práticas e as condições de viabilidade das abordagens clássica e híbrida quântico-clássica em múltiplos domínios visuais.

1.5 Hipótese

Parte-se da hipótese de que uma arquitetura híbrida quântico-clássica, utilizando circuitos quânticos parametrizados simulados como cabeça de classificação acoplada a um extrator convolucional clássico, pode alcançar convergência estável e desempenho competitivo (superior ao acaso e próximo ao *baseline* clássico em bases de menor cardinalidade de classes) quando submetida a um protocolo experimental controlado, mantendo-se constantes as divisões de dados, o pré-processamento e os critérios de otimização.

Entretanto, não se pressupõe superioridade irrestrita da abordagem híbrida sobre as CNNs puramente clássicas. Considerando o gargalo de compressão dimensional exigido pelo número reduzido de qubits, o custo exponencial da simulação clássica de estados quânticos e a dificuldade de separação em problemas com dezenas de classes ou alta variabilidade intraclasse (como GTSRB, FER2013 e CIFAR-100), espera-se que a viabilidade prática dos modelos híbridos seja fortemente condicionada pela complexidade do *dataset*, pelo dimensionamento do lote (*batch size*) e pela eficiência do acoplamento entre a extração clássica e o circuito variacional.

1.6 Delimitações do trabalho

Este trabalho é delimitado como um estudo experimental comparativo em visão computacional e aprendizado de máquina. A tarefa investigada restringe-se à classificação supervisionada de imagens estáticas bidimensionais distribuídas em nove conjuntos de dados públicos de referência. Os experimentos com circuitos quânticos são conduzidos integralmente via simulação numérica em hardware clássico, não contemplando execução direta em processadores quânticos físicos (QPUs), de modo a isolar o comportamento algorítmico das arquiteturas das imperfeições de ruído físico de hardware externo e garantir total reprodutibilidade dos treinamentos.

2 Revisão Bibliográfica

2.1 Metodologia da pesquisa bibliográfica

A pesquisa bibliográfica deste trabalho foi conduzida com o objetivo de fundamentar teórica e metodologicamente o estudo comparativo entre redes neurais convolucionais clássicas e modelos híbridos quântico-clássicos aplicados à classificação de imagens em múltiplos *benchmarks* de visão computacional.

As buscas foram realizadas em bases científicas nacionais e internacionais, incluindo Google Scholar, IEEE Xplore, ACM Digital Library, Scopus, SpringerLink, SciELO e Portal de Periódicos da CAPES, além de repositórios de pré-publicações como o arXiv para acompanhar desenvolvimentos recentes em Aprendizado de Máquina Quântico. A escolha dessas bases justifica-se pela sua abrangência nas áreas de Ciência da Computação, Inteligência Artificial, processamento digital de imagens, redes neurais profundas e computação quântica.

Foram utilizadas palavras-chave em português e inglês combinadas por operadores booleanos. Entre os principais termos estão: *"classificação de imagens"*, *"visão computacional"*, *"redes neurais convolucionais"*, *"aprendizado profundo"*, *"benchmarks de imagens"*, *"computação quântica"*, *"aprendizado de máquina quântico"*, *"modelos híbridos quântico-clássicos"*, *"image classification"*, *"computer vision benchmarks"*, *"convolutional neural network"*, *"deep learning"*, *"activation functions"*, *"batch size optimization"*, *"neural network quantization"*, *"quantum machine learning"*, *"variational quantum circuit"* e *"hybrid quantum-classical neural network"*.

As *strings* de busca foram organizadas em cinco blocos temáticos:

1. Fundamentos de processamento digital de imagens, classificação supervisionada multiclasse e métricas de avaliação em cenários balanceados e desbalanceados;

2. Arquiteturas de redes neurais convolucionais (CNNs), funções de ativação, impacto do tamanho de lote (*batch size*), regularização, aumento de dados e quantização de modelos;

3. Conjuntos de dados e *benchmarks* clássicos e modernos de visão computacional (MNIST, Fashion-MNIST, KMNIST, EMNIST, CIFAR-10, CIFAR-100, SVHN, GTSRB e FER2013);

4. Fundamentos de computação quântica, circuitos quânticos parametrizados, estratégias de codificação de dados (*quantum embeddings*) e limitações de treinabilidade (*barren plateaus*);

5. Arquiteturas híbridas quântico-clássicas e camadas quanvolucionais aplicadas ao reconhecimento visual.

Como critérios de inclusão, priorizaram-se trabalhos publicados entre 2020 e 2026 que abordam diretamente arquiteturas convolucionais, otimização de treinamento, *benchmarks* multi-dataset e modelos híbridos quântico-clássicos, complementados por obras seminais e livros-texto clássicos essenciais para a formalização matemática dos algoritmos e para a documentação original das bases de dados utilizadas.

2.2 Classificação de imagens e diversidade de domínios em visão computacional

Esta seção apresenta os conceitos fundamentais relacionados aos diferentes domínios visuais abordados em *benchmarks* de visão computacional. O objetivo é contextualizar as propriedades visuais, estruturais e estatísticas que diferenciam tarefas de reconhecimento de caracteres, objetos, sinais de trânsito e expressões faciais.

2.2.1 Reconhecimento de dígitos, caracteres e símbolos manuscritos

O reconhecimento óptico de caracteres e dígitos manuscritos constitui uma das aplicações precursoras da visão computacional e do aprendizado profundo (LECUN; BENGIO; HINTON, 2015). Nesse domínio, as imagens são tipicamente adquiridas ou pré-processadas em escala de cinza ($C = 1$), com o objeto de interesse centralizado sobre um fundo uniforme de baixo ruído. A informação discriminativa concentra-se na topologia dos traços, nas curvaturas, nas extremidades e nas interseções geométricas.

Enquanto dígitos arábicos ocidentais (como no conjunto MNIST) apresentam dez classes bem definidas e baixa ambiguidade estrutural, extensões alfanuméricas (como o EMNIST) e sistemas de escrita historicamente complexos — a exemplo dos caracteres cursivos japoneses Kuzushiji no KMNIST — introduzem variações caligráficas acentuadas, maior número de classes ou múltiplas formas visuais para representar um mesmo fonema ou conceito. Em cenários não controlados, como a leitura de números residenciais em cenas urbanas (SVHN), o reconhecimento de dígitos deixa de ocorrer sobre fundo limpo e passa a enfrentar variações severas de iluminação, fontes tipográficas diversas, desfoque de movimento e interferência de dígitos adjacentes.

2.2.2 Categorização de artigos de vestuário, objetos naturais e sinalização viária

À medida que a visão computacional avança de símbolos gráficos para objetos do mundo físico, a complexidade textural e espacial das imagens aumenta significativamente.

No reconhecimento de artigos de vestuário em escala de cinza (como no Fashion-MNIST), embora a resolução espacial reduzida (28×28 pixels) seja idêntica à de bases de dígitos, os objetos apresentam silhuetas preenchidas, texturas internas sutis e forte similaridade interclasse (como entre camisas, camisetas, casacos e pulôveres).

Em imagens naturais coloridas (representadas no espaço RGB com $C = 3$ canais), como nos conjuntos CIFAR-10 e CIFAR-100, os modelos precisam distinguir categorias animais e veículos em resoluções compactas (32×32 pixels), nas quais o objeto de interesse convive com fundos complexos, oclusões parciais e variações de pose e escala. De forma análoga, o reconhecimento de placas de trânsito em ambientes reais (como no *benchmark* GTSRB) exige que o classificador seja robusto a mudanças drásticas de iluminação diurna e noturna, intempéries climáticas, distorções de perspectiva e desbalanceamento acentuado entre categorias de sinalização frequentes e raras.

2.2.3 Reconhecimento de expressões faciais e desafios de variabilidade intraclasse

O reconhecimento automático de expressões faciais (como na base FER2013) representa um domínio particularmente desafiador dentro da classificação supervisionada de imagens. Diferentemente de objetos rígidos ou símbolos gráficos, a face humana sofre deformações não rígidas sutis nos músculos ao redor dos olhos, sobrancelhas e boca para expressar estados emocionais como raiva, desgosto, medo, felicidade, tristeza, surpresa e neutralidade.

Do ponto de vista computacional, esse domínio caracteriza-se por uma elevada variabilidade intraclasse — pessoas de diferentes idades, etnias, gêneros e condições de iluminação expressam a mesma emoção de maneiras distintas — combinada a uma baixa separabilidade interclasse, uma vez que expressões como medo e surpresa, ou tristeza e neutralidade, compartilham configurações geométricas muito próximas. Além disso, bases coletadas em condições não controladas (*in-the-wild*) costumam apresentar rótulos ruidosos, oclusões por óculos ou mãos e forte assimetria na quantidade de exemplos por classe, exigindo arquiteturas com alta capacidade de regularização.

2.3 Bases de dados e benchmarks utilizados no estudo

A utilização de múltiplos conjuntos de dados públicos e padronizados é essencial para avaliar a capacidade de generalização, a estabilidade numérica e a escalabilidade de algoritmos de aprendizado de máquina. A adoção de um *benchmark* multi-dataset evita que conclusões arquiteturais fiquem restritas às peculiaridades estatísticas de uma única fonte de dados, permitindo contrastar o desempenho de modelos clássicos e híbridos em diferentes regimes de resolução, dimensionalidade de canais e número de classes.

2.3.1 Importância da avaliação multi-dataset em aprendizado profundo e quântico

Na literatura de visão computacional, arquiteturas que apresentam excelente desempenho em bases simples de dígitos frequentemente sofrem degradação expressiva quando submetidas a imagens com texturas densas, múltiplos canais de cor ou dezenas de classes. No campo do Aprendizado de Máquina Quântico, essa questão é ainda mais crítica: como circuitos quânticos simulados operam com poucos qubits, a redução dimensional imposta pelo extrator clássico pode preservar informações suficientes para separar dez classes simples, mas colapsar representações em domínios mais complexos.

Por esse motivo, o protocolo experimental deste trabalho foi desenhado sobre um conjunto diversificado de nove bases de dados, documentadas e gerenciadas de forma centralizada no repositório do projeto (`<configs/datasets.yaml>` e `<notebooks/dataset_inventory.ipynb>`). Essa seleção abrange desde *benchmarks* canônicos de validação rápida até problemas multiclasse com forte desbalanceamento e ruído visual.

2.3.2 Caracterização dos 9 conjuntos de dados do benchmark

Os nove conjuntos de dados adotados nos experimentos compreendem diferentes domínios de aplicação, resoluções nativas, quantidades de canais e números de classes:

1. **MNIST** (*Modified National Institute of Standards and Technology*): Base clássica composta por 70.000 imagens em escala de cinza ($28 \times 28 \times 1$) de dígitos manuscritos de 0 a 9 (10 classes), dividida originalmente em 60.000 amostras de treino e 10.000 de teste. Atua como linha de base (*sanity check*) fundamental para convergência de arquiteturas clássicas e híbridas.

2. **Fashion-MNIST**: Proposta como substituição direta e mais desafiadora ao MNIST, contém 70.000 imagens em escala de cinza ($28 \times 28 \times 1$) distribuídas equilibradamente em 10 classes de artigos de vestuário (camiseta/top, calça, pulôver, vestido, casaco, sandália, camisa, tênis, bolsa e bota).

3. **KMNIST** (*Kuzushiji-MNIST*): Composta por 70.000 imagens em escala de cinza ($28 \times 28 \times 1$) distribuídas em 10 classes de caracteres cursivos japoneses (Hiragana clássico), apresentando topologias de traços significativamente mais complexas e maior variação intraclasse do que os dígitos arábicos.

4. **EMNIST** (*Extended MNIST*): Extensão do conjunto NIST original contendo caracteres manuscritos alfanuméricos (letras maiúsculas, minúsculas e dígitos) em imagens de $28 \times 28 \times 1$ em escala de cinza, ampliando a dificuldade da tarefa pelo aumento substancial do número de classes e pela presença de ambiguidades estruturais entre letras e números (como “O” e “0”, ou “I”, “l” e “1”).

5. **CIFAR-10**: Conjunto de 60.000 imagens naturais coloridas em formato RGB ($32 \times 32 \times 3$), sendo 50.000 para treinamento e 10.000 para teste, divididas igualmente em 10 classes de objetos e animais (avião, automóvel, pássaro, gato, cervo, cachorro, sapo, cavalo, navio e caminhão).

6. **CIFAR-100**: Possui a mesma estrutura física e volume total do CIFAR-10 (60.000 imagens RGB de $32 \times 32 \times 3$), mas distribuídas em 100 classes finas agrupadas em 20 superclasses, reduzindo para apenas 600 o número de amostras por classe e elevando drasticamente a exigência de capacidade discriminativa do classificador.

7. **SVHN** (*Street View House Numbers*): Base de imagens reais obtidas a partir de fachadas residenciais no Google Street View, contendo dígitos recortados e centralizados em resolução $32 \times 32 \times 3$ (RGB) distribuídos em 10 classes (dígitos de 0 a 9, com mais de 73.257 imagens de treino e 26.032 de teste), caracterizada por variações severas de iluminação, contraste e presença de dígitos laterais distratores.

8. **GTSRB** (*German Traffic Sign Recognition Benchmark*): Conjunto composto por mais de 50.000 imagens RGB de placas de trânsito alemãs reais capturadas sob variadas condições de iluminação e distância, redimensionadas para resolução padronizada (como $32 \times 32 \times 3$) e distribuídas de forma fortemente desbalanceada ao longo de 43 classes distintas.

9. **FER2013** (*Facial Expression Recognition 2013*): Base composta por 35.887 imagens faciais em escala de cinza ($48 \times 48 \times 1$) distribuídas em 7 classes de expressões emocionais básicas (raiva, desgosto, medo, felicidade, tristeza, surpresa e neutro), apresentando forte desbalanceamento (especialmente na classe desgosto) e ruído de rotulagem inerente à coleta automatizada.

A Tabela 1 sintetiza a caracterização estrutural das nove bases de dados utilizadas na campanha experimental.

Tabela 1 – Caracterização estrutural dos 9 conjuntos de dados utilizados no *benchmark*.

Base	**Domínio**	**Dimensão**	**Canais**	**Classes (K)**	**Volume aprox.**	**Balanceamento**
MNIST	Dígitos manuscritos	$28 \times 28 \times 1$	Cinza (1)	10	~ 70.000	Quase uniforme
Fashion-MNIST	Artigos de vestuário	$28 \times 28 \times 1$	Cinza (1)	10	~ 70.000	Uniforme (7.000/classe)
KMNIST	Caracteres Kuzushiji	$28 \times 28 \times 1$	Cinza (1)	10	~ 70.000	Uniforme (7.000/classe)
EMNIST	Caracteres alfanuméricos	$28 \times 28 \times 1$	Cinza (1)	26 / 47 / 62*	145.600 a 814.255*	Balanceado ou variável por *split*
CIFAR-10	Objetos e animais	$32 \times 32 \times 3$	RGB (3)	10	~ 60.000	Uniforme (6.000/classe)
CIFAR-100	Objetos granulares	$32 \times 32 \times 3$	RGB (3)	100	~ 60.000	Uniforme (600/classe)
SVHN	Números de fachadas	$32 \times 32 \times 3$	RGB (3)	10	~ 99.289	Desbalanceado (predomínio de "1" e "2")
GTSRB	Placas de trânsito	$32 \times 32 \times 3$**	RGB (3)	43	~ 51.839	Fortemente desbalanceado
FER2013	Expressões faciais	$48 \times 48 \times 1$	Cinza (1)	7	~ 35.887	Fortemente desbalanceado

Fonte: Elaborado pelo autor (2026). *O número exato de classes e amostras do EMNIST depende da partição configurada em `configs/datasets.yaml`. **As imagens originais do GTSRB variam de 15×15 a 250×250 pixels e são redimensionadas no *pipeline* de pré-processamento.

2.3.3 Qualidade dos rótulos, desbalanceamento e heterogeneidade entre domínios

A análise conjunta das nove bases de dados evidencia desafios metodológicos distintos que justificam um protocolo rigoroso de avaliação. Em tarefas de classificação supervisionada, o desbalanceamento de classes — fortemente presente em bases reais como SVHN, GTSRB e FER2013 — tende a enviesar o gradiente de otimização em direção às classes majoritárias, reduzindo a sensibilidade do modelo para categorias minoritárias.

Segundo Silva (2025), estratégias de mitigação desse efeito podem atuar tanto em nível de dados (amostragem estratificada, *oversampling*, *undersampling* e aumento de dados direcionado) quanto em nível algorítmico (ponderação na função de perda e uso de métricas insensíveis à prevalência global). Além do desbalanceamento, a heterogeneidade entre domínios — alternando entre imagens monocromáticas de 28×28 ou 48×48 pixels e imagens RGB de 32×32 pixels — exige que o *pipeline* de avaliação reporte sistematicamente métricas agregadas de forma igualitária entre classes, como o Macro-F1, acompanhadas das matrizes de confusão e dos resíduos de desempenho por classe, garantindo uma comparação justa entre as arquiteturas clássica e híbrida.

2.4 Imagens digitais e classificação computacional

A classificação computacional de imagens depende da representação de informações visuais em estruturas numéricas manipuláveis por algoritmos. Em processamento digital de imagens, uma imagem pode ser formalmente descrita como uma função bidimensional discreta, composta por elementos finitos denominados pixels, cada um associado a uma posição espacial e a um ou mais valores de intensidade (GONZALEZ; WOODS, 2008). Em *benchmarks* de visão computacional, essa representação é fundamental, pois variações locais de intensidade, bordas, textura e contraste de cor determinam os padrões geométricos que diferenciam as classes de interesse. As redes neurais convolucionais consolidaram-se como a abordagem padrão para esse tipo de problema porque exploram diretamente a organização espacial das imagens por meio de filtros convolucionais aprendidos durante o treinamento, preservando relações de vizinhança entre pixels (LECUN; BENGIO; HINTON, 2015).

2.4.1 Representação computacional de imagens digitais

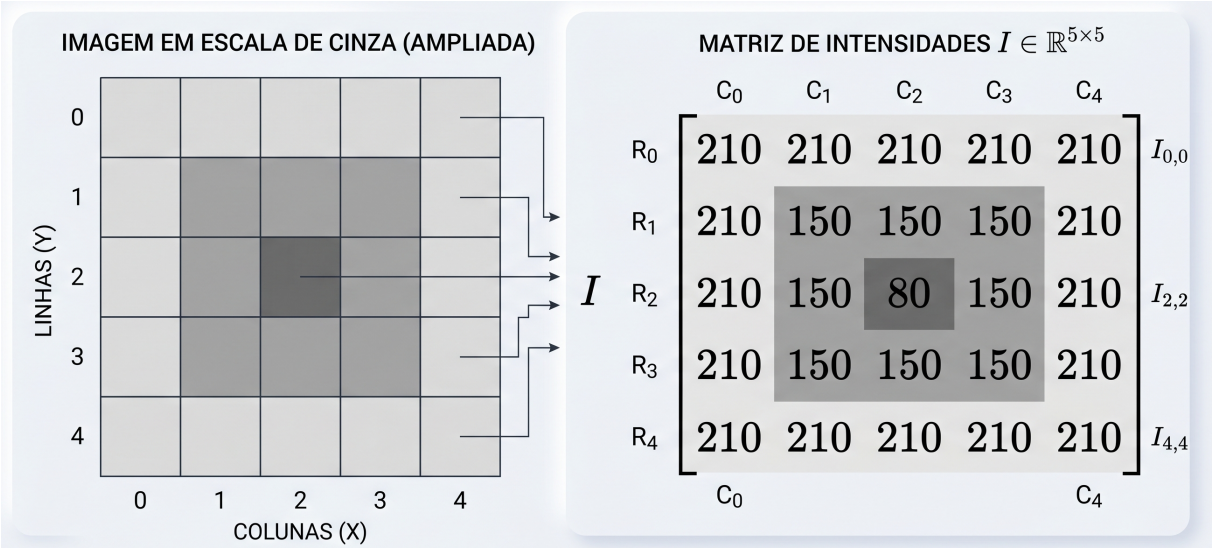
Uma imagem digital pode ser compreendida matematicamente como uma função bidimensional discreta, geralmente representada por $I(x, y)$, em que x e y indicam as coordenadas espaciais do pixel e $I(x, y)$ representa o valor de intensidade naquele ponto da imagem. Em uma imagem em escala de cinza, como ocorre em bases monocromáticas de caracteres, artigos de vestuário e faces, cada pixel possui apenas um valor numérico

associado à luminosidade local. Assim, uma imagem monocromática com altura H e largura W pode ser representada como uma matriz:

$$I \in \mathbb{R}^{H \times W}$$

A Figura 1 apresenta uma representação simplificada dessa estrutura matricial. No exemplo, a imagem em escala de cinza é ampliada como uma grade 5×5, na qual cada célula corresponde a um pixel. Ao lado, a mesma imagem é representada por uma matriz de intensidades, em que valores maiores indicam regiões mais claras e valores menores indicam regiões mais escuras.

Figura 1 – Representação matemática de uma imagem em escala de cinza como matriz de intensidades.



Fonte: Elaborado pelo autor (2026).

Em termos matemáticos, cada elemento $I_{i,j}$ corresponde ao valor de intensidade do pixel localizado na linha i e na coluna j. Em imagens de 8 bits, por exemplo, esses valores normalmente variam entre 0 e 255, sendo 0 associado ao preto, 255 ao branco e os valores intermediários aos diferentes tons de cinza. Em problemas de visão computacional, essa variação espacial de intensidade codifica contornos, gradientes de iluminação, texturas superficiais e estruturas morfológicas essenciais para discriminar o objeto de interesse.

Antes de ser utilizada por um modelo de aprendizado profundo, a imagem costuma passar por uma etapa de normalização. Uma forma simples de normalização consiste em dividir cada valor de pixel por 255, transformando a escala original para o intervalo entre 0 e 1:

$$I'_{i,j} = \frac{I_{i,j}}{255}$$

Essa transformação não altera a estrutura espacial da imagem, mas facilita o treinamento da rede neural, pois reduz a variação numérica dos dados de entrada. Em termos

computacionais, uma imagem digital é representada de forma geral como um tensor de três dimensões:

$$I \in \mathbb{R}^{H \times W \times C}$$

em que H representa a altura, W a largura e C o número de canais de cor. Em bases monocromáticas (escala de cinza), como MNIST, Fashion-MNIST, KMNIST, EMNIST ($28 \times 28 \times 1$) e FER2013 ($48 \times 48 \times 1$), tem-se $C = 1$. Já em bases de imagens coloridas no espaço RGB, como CIFAR-10, CIFAR-100, SVHN e GTSRB ($32 \times 32 \times 3$), tem-se $C = 3$. Quando várias imagens são processadas simultaneamente durante o treinamento ou inferência, organiza-se um lote (*batch*) de imagens representado pelo tensor de quarta ordem:

$$X \in \mathbb{R}^{N \times H \times W \times C}$$

em que N indica o tamanho do lote (*batch size*, como $N \in \{32, 64, 128, 256\}$).

No contexto da classificação supervisionada multiclasse, cada imagem x é associada a um rótulo discreto $y \in \{0, 1, \ldots, K-1\}$, em que K representa o número total de classes do conjunto de dados (por exemplo, $K = 7$ no FER2013, $K = 10$ no MNIST, Fashion-MNIST, KMNIST, CIFAR-10 e SVHN, $K = 43$ no GTSRB e $K = 100$ no CIFAR-100). O objetivo do modelo computacional é aprender uma função $f_\theta(x)$, parametrizada por pesos treináveis θ, capaz de receber o tensor da imagem como entrada e produzir uma distribuição de probabilidade sobre as K classes possíveis:

$$f_\theta(x) = [p_0, p_1, \ldots, p_{K-1}]$$

sendo a classe final prevista obtida pela regra de decisão de máxima probabilidade a posteriori:

$$\hat{y} = \arg \max_{k \in \{0,\ldots,K-1\}} p_k$$

Essa formulação mostra que a classificação computacional de imagens não ocorre diretamente sobre a imagem visual percebida por um ser humano, mas sobre uma representação numérica estruturada. A imagem é convertida em matriz ou tensor, seus valores são normalizados, os rótulos são codificados numericamente e o modelo aprende padrões estatísticos capazes de relacionar regiões da imagem às classes de interesse.

Nas redes neurais convolucionais, esse processo é realizado por meio de filtros ou núcleos convolucionais que percorrem a imagem extraindo padrões locais. Um filtro K de tamanho $m \times n$ é aplicado sobre pequenas regiões da imagem, produzindo novos mapas de características. De forma simplificada, a operação convolucional pode ser representada por:

$$S(i,j) = \sum_{u=0}^{m-1} \sum_{v=0}^{n-1} K(u,v) \cdot I(i+u, j+v)$$

Nesse caso, o filtro funciona como uma janela que analisa regiões locais da imagem. Dependendo dos valores aprendidos pelo filtro durante o treinamento, ele pode se tornar sensível a bordas, texturas, variações de contraste, formas ou padrões mais complexos. Em *benchmarks* de visão computacional, essa propriedade é fundamental porque elementos discriminativos — como traços caligráficos em caracteres, contornos de objetos naturais, pictogramas em placas de trânsito ou curvaturas faciais — dependem diretamente das relações locais entre pixels vizinhos.

Portanto, a representação computacional de imagens digitais estabelece a ponte entre o sinal visual bruto e os modelos de aprendizado profundo e híbridos quântico-clássicos, permitindo que informações visuais de múltiplos domínios sejam transformadas em tensores numéricos processáveis.

2.4.2 Classificação supervisionada de imagens

A classificação supervisionada de imagens é uma tarefa de aprendizado de máquina na qual um modelo aprende a associar imagens de entrada a rótulos previamente definidos. Diferentemente de abordagens não supervisionadas, nas quais o algoritmo busca padrões sem classes conhecidas, no aprendizado supervisionado cada amostra do conjunto de dados possui uma saída esperada, também chamada de rótulo ou *ground truth*. Em *benchmarks* de visão computacional, esses rótulos representam as categorias semânticas de cada domínio, como dígitos, caracteres, peças de vestuário, objetos naturais, sinais viários ou expressões faciais.

Do ponto de vista matemático, um conjunto de dados supervisionado pode ser representado por:

$$\mathcal{D} = \{(x_1, y_1), (x_2, y_2), \ldots, (x_N, y_N)\},$$

em que x_i representa a i-ésima imagem e y_i representa seu respectivo rótulo. Em uma tarefa de classificação com K classes, cada rótulo pertence ao conjunto:

$$y_i \in \{0, 1, \ldots, K-1\}.$$

Assim, a cardinalidade K adapta-se diretamente à granularidade semântica da base avaliada, abrangendo desde problemas com $K = 7$ ou $K = 10$ categorias até cenários com dezenas ou centenas de classes ($K = 43$ no GTSRB e $K = 100$ no CIFAR-100).

Segundo Deisenroth, Faisal e Ong (2020), a aprendizagem de máquina pode ser compreendida a partir de três componentes principais: dados, modelo e aprendizagem. Os dados precisam ser representados numericamente; o modelo é uma função parametrizada; e a

aprendizagem corresponde ao ajuste dos parâmetros desse modelo com base nos exemplos disponíveis. No caso de imagens digitais, cada amostra é descrita como um tensor:

$$x_i \in \mathbb{R}^{H \times W \times C},$$

em que H representa a altura, W representa a largura e C representa o número de canais ($C = 1$ em imagens em escala de cinza e $C = 3$ em imagens coloridas RGB). Dessa forma, a imagem passa a ser uma estrutura matemática processável por algoritmos de otimização.

O objetivo de um modelo supervisionado é aprender uma função parametrizada capaz de mapear a entrada x_i para uma saída associada às K classes possíveis:

$$f_\theta : \mathbb{R}^{H \times W \times C} \to \mathbb{R}^K,$$

em que θ representa o conjunto de parâmetros aprendidos pelo modelo. Em redes neurais, esses parâmetros correspondem aos pesos e vieses das camadas (e, em modelos híbridos, incluem os ângulos de rotação das portas quânticas parametrizadas). A saída da rede geralmente é um vetor de escores (*logits*), convertido em probabilidades por meio da função *softmax*:

$$p_k = \frac{e^{s_k}}{\sum_{j=0}^{K-1} e^{s_j}},$$

em que s_k é o escore associado à classe k, e p_k representa a probabilidade estimada para essa classe. A classe prevista pelo modelo é dada por:

$$\hat{y} = \arg\max_k p_k.$$

Assim, o modelo atribui à imagem a classe que possui maior probabilidade estimada. Por exemplo, em uma tarefa ilustrativa com três classes, se a saída do modelo para uma amostra for:

$$\hat{p} = [0{,}12,\ 0{,}23,\ 0{,}65],$$

então a classe prevista será a terceira classe ($k = 2$), pois 0,65 é o maior valor do vetor de probabilidades.

Durante o treinamento, a predição do modelo é comparada com o rótulo verdadeiro por meio de uma função de perda. Em problemas multiclasse, uma função amplamente utilizada é a entropia cruzada categórica (*categorical cross-entropy*):

$$\mathcal{L}(y, \hat{p}) = -\sum_{k=0}^{K-1} y_k \log(p_k),$$

em que y_k representa o rótulo verdadeiro em codificação *one-hot*. Quando a classe correta é c, essa expressão pode ser simplificada para:

$$\mathcal{L}(y, \hat{p}) = -\log(p_c).$$

Portanto, a perda será baixa quando o modelo atribuir alta probabilidade à classe correta e será alta quando o modelo atribuir baixa probabilidade ao rótulo verdadeiro. O treinamento consiste em ajustar os parâmetros θ para minimizar essa perda ao longo do conjunto de dados, processo diretamente relacionado à otimização matemática em aprendizado de máquina (DEISENROTH; FAISAL; ONG, 2020; GOODFELLOW; BENGIO; COURVILLE, 2016).

Em *benchmarks* de visão computacional com diferentes níveis de balanceamento e ruído visual, a classificação supervisionada exige cuidados metodológicos específicos. Bases coletadas em cenários reais (como SVHN, GTSRB e FER2013) apresentam variações acentuadas de iluminação, contraste, resolução nativa e distribuição entre classes, além de possíveis ambiguidades de rotulagem. Essas características tornam indispensável a padronização do pré-processamento, da divisão estratificada dos dados e das métricas de avaliação para assegurar comparações justas entre arquiteturas distintas.

2.4.3 Treinamento, validação, teste e generalização

Em aprendizado supervisionado, a avaliação adequada de um modelo depende da separação do conjunto de dados em subconjuntos com funções distintas. De modo geral, os dados são divididos em treino, validação e teste. O conjunto de treino é utilizado para ajustar os parâmetros do modelo; o conjunto de validação auxilia no acompanhamento do desempenho e na escolha de hiperparâmetros; e o conjunto de teste é reservado para estimar o desempenho final em dados não vistos.

Essa divisão é essencial porque o objetivo de um modelo de aprendizado de máquina não é apenas memorizar os exemplos usados no treinamento, mas generalizar para novas amostras. Deisenroth, Faisal e Ong (2020) ressaltam que o aprendizado deve buscar desempenho em dados ainda não observados, e não apenas bom ajuste aos dados disponíveis. Em estudos multi-dataset, essa questão é central, pois uma configuração arquitetural ou de hiperparâmetros pode convergir rapidamente em bases canônicas de dígitos e apresentar degradação severa de generalização em imagens naturais ou expressões faciais.

Durante o treinamento, o modelo recebe os exemplos do conjunto de treino e atualiza seus parâmetros com base no erro calculado. Considerando uma função de perda $\mathcal{L}$, o treinamento pode ser descrito pela minimização do risco empírico:

$$R_{\text{emp}}(\theta) = \frac{1}{N} \sum_{i=1}^{N} \mathcal{L}(y_i, f_\theta(x_i)).$$

O risco empírico mede o erro médio do modelo sobre os dados disponíveis para treinamento. No entanto, o interesse real está no desempenho esperado em dados novos. A

diferença entre o erro de treino e o erro em validação ou teste está relacionada à capacidade de generalização do modelo.

A atualização dos parâmetros pode ser representada, de forma simplificada, por uma etapa de gradiente descendente:

$$\theta_{t+1} = \theta_t - \eta \nabla_\theta R_{\text{emp}}(\theta_t),$$

em que θ_t representa os parâmetros na iteração t, η é a taxa de aprendizado e $\nabla_\theta R_{\text{emp}}(\theta_t)$ é o gradiente da função de perda em relação aos parâmetros. Esse processo é repetido ao longo de várias épocas, até que o modelo alcance um desempenho adequado ou até que critérios de parada sejam satisfeitos.

O conjunto de validação é utilizado para acompanhar o comportamento do modelo durante o treinamento. Ele permite verificar se a redução da perda no treino está acompanhada de melhora em dados não utilizados diretamente na atualização dos pesos. Além disso, a validação auxilia na escolha de hiperparâmetros, como taxa de aprendizado, função de ativação, tamanho do lote (*batch size*), número de épocas, intensidade de regularização e estratégia de aumento de dados.

O conjunto de teste, por sua vez, deve ser utilizado somente ao final do processo de desenvolvimento. Sua função é fornecer uma estimativa imparcial do desempenho final do modelo. Caso o conjunto de teste seja usado repetidamente para tomar decisões de modelagem, ele deixa de representar uma avaliação independente, pois passa a influenciar indiretamente o ajuste do modelo.

A generalização pode ser compreendida como a capacidade do modelo de manter desempenho satisfatório em exemplos que não participaram do treinamento. Quando o modelo apresenta baixo erro no treino, mas erro elevado na validação ou no teste, ocorre o fenômeno conhecido como *overfitting*, ou sobreajuste. Nesse caso, o modelo aprende detalhes específicos do conjunto de treino, como ruídos de fundo, artefatos de compressão ou particularidades amostrais, em vez de aprender padrões gerais associados às classes.

O comportamento típico do sobreajuste pode ser representado por:

$$\mathcal{L}_{train} \downarrow \quad \text{e} \quad \mathcal{L}_{val} \uparrow,$$

ou seja, a perda de treino continua diminuindo enquanto a perda de validação aumenta ou deixa de melhorar. Também pode ocorrer quando a métrica de desempenho no treino cresce continuamente, mas na validação se estabiliza ou diminui. Goodfellow, Bengio e Courville (2016) discutem esse problema como uma das principais limitações de modelos de alta capacidade, especialmente quando a quantidade de exemplos por classe é reduzida (como no CIFAR-100 ou nas classes minoritárias do GTSRB e FER2013).

O fenômeno oposto é o *underfitting*, ou subajuste. Ele ocorre quando o modelo não consegue aprender adequadamente nem mesmo os padrões presentes no conjunto de treino.

Nesse caso, tanto o desempenho no treino quanto o desempenho na validação permanecem baixos. O subajuste pode ocorrer quando a arquitetura possui baixa capacidade representacional, quando há compressão excessiva de características (como em gargalos quânticos muito estreitos) ou quando o regime de otimização é insuficiente.

Outro cuidado metodológico indispensável é a prevenção de vazamento de dados (*data leakage*) e a adoção de divisão estratificada entre treino, validação e teste. Em bases desbalanceadas, a partição estratificada preserva a proporção original das K classes em todos os subconjuntos, garantindo que categorias minoritárias estejam adequadamente representadas tanto durante o ajuste dos parâmetros quanto na avaliação final.

2.4.4 Métricas de avaliação

A avaliação de modelos de classificação em visão computacional deve ser compreendida a partir da formulação matemática geral do aprendizado supervisionado. Nesse contexto, considera-se um conjunto de dados composto por pares de entrada e rótulo:

$$\mathcal{D} = \{(x_1, y_1), (x_2, y_2), \ldots, (x_N, y_N)\},$$

em que x_i representa uma imagem de entrada e $y_i \in \{0, 1, \ldots, K-1\}$ representa seu rótulo verdadeiro entre as K classes do conjunto de dados avaliado.

Segundo Deisenroth, Faisal e Ong (2020), em uma tarefa de classificação multiclasse, o modelo pode ser representado por uma função parametrizada:

$$f_\theta : \mathbb{R}^D \to \mathbb{R}^K,$$

em que D representa a dimensão da entrada após sua representação numérica, K representa o número de classes e θ representa o conjunto de parâmetros do modelo. Para uma imagem x_i, o modelo produz um vetor de probabilidades via *softmax*:

$$\hat{p}_i = f_\theta(x_i) = [p_{i,0}, p_{i,1}, \ldots, p_{i,K-1}],$$

em que $p_{i,k}$ representa a probabilidade estimada de a imagem x_i pertencer à classe k, e a classe prevista é obtida por:

$$\hat{y}_i = \arg\max_k p_{i,k}.$$

Durante o treinamento, minimiza-se o risco empírico:

$$R_{\text{emp}}(f_\theta) = \frac{1}{N} \sum_{i=1}^{N} \ell(y_i, f_\theta(x_i)),$$

utilizando-se tipicamente a entropia cruzada categórica:

$$\mathcal{L}(y_i, \hat{p}_i) = -\sum_{k=0}^{K-1} y_{i,k} \log(p_{i,k}),$$

que para a classe verdadeira c se reduz a $\mathcal{L}(y_i, \hat{p}_i) = -\log(p_{i,c})$. Entretanto, a função de perda utilizada na otimização contínua não é suficiente para caracterizar de forma completa a qualidade discriminativa do classificador nas K classes. Por isso, são utilizadas métricas de avaliação discretas e probabilísticas calculadas sobre os conjuntos de validação e teste.

A métrica mais direta é a acurácia, que mede a proporção de classificações corretas em relação ao total de amostras avaliadas:

$$Accuracy = \frac{1}{N} \sum_{i=1}^{N} \mathbb{1}(\hat{y}_i = y_i),$$

em que $\mathbb{1}(\hat{y}_i = y_i)$ é uma função indicadora que assume valor 1 quando a predição está correta e 0 caso contrário. Embora seja uma métrica intuitiva, a acurácia global pode ser enganosa em bases desbalanceadas, nas quais um classificador obtém valores elevados apenas por favorecer as categorias mais frequentes.

Para uma análise detalhada por categoria, utiliza-se a matriz de confusão. Em um problema com K classes, a matriz de confusão é definida por:

$$C \in \mathbb{N}^{K \times K},$$

em que cada elemento C_{ij} indica a quantidade de exemplos cuja classe verdadeira é i e cuja classe prevista é j. De forma ilustrativa, para $K = 3$, tem-se:

$$C = \begin{bmatrix} C_{00} & C_{01} & C_{02} \\ C_{10} & C_{11} & C_{12} \\ C_{20} & C_{21} & C_{22} \end{bmatrix}.$$

Os elementos da diagonal principal C_{kk} contabilizam os acertos do modelo para cada classe k, enquanto os elementos fora da diagonal C_{ij} $(i \neq j)$ revelam confusões semânticas ou morfológicas específicas de cada base (como a confusão entre camisa e camiseta no Fashion-MNIST, entre expressões faciais próximas no FER2013 ou entre caracteres cursivos semelhantes no KMNIST).

A partir da matriz de confusão, é possível calcular métricas específicas por classe usando a estratégia *one-vs-rest*. Nessa abordagem, para cada classe k, considera-se essa classe como positiva e todas as demais como negativas. Assim, definem-se:

$$TP_k = C_{kk},$$

$$FN_k = \sum_{\substack{j=0 \\ j \neq k}}^{K-1} C_{kj},$$

$$FP_k = \sum_{\substack{i=0 \\ i \neq k}}^{K-1} C_{ik},$$

$$TN_k = \sum_{\substack{i=0 \\ i \neq k}}^{K-1} \sum_{\substack{j=0 \\ j \neq k}}^{K-1} C_{ij}.$$

Nessas expressões, TP_k representa os verdadeiros positivos da classe k, isto é, exemplos da classe k corretamente classificados como k. FN_k representa os falsos negativos, ou seja, exemplos da classe k classificados como outra classe. FP_k representa os falsos positivos, isto é, exemplos de outras classes classificados incorretamente como k. Por fim, TN_k representa os verdadeiros negativos, ou seja, exemplos que não pertencem à classe k e também não foram classificados como k.

A precisão da classe k é definida por:

$$Precision_k = \frac{TP_k}{TP_k + FP_k}.$$

Essa métrica indica, entre todas as imagens classificadas pelo modelo como pertencentes à classe k, quantas realmente pertencem a essa classe. Uma baixa precisão para determinada categoria indica que o modelo atribui excessivamente esse rótulo a amostras de outras classes, elevando a taxa de falsos positivos.

A revocação (*recall*) ou sensibilidade é definida por:

$$Recall_k = Sensitivity_k = \frac{TP_k}{TP_k + FN_k}.$$

Essa métrica indica a proporção de exemplos reais da classe k que foram corretamente identificados pelo modelo. Em classes minoritárias (como sinais de trânsito raros no GTSRB ou a expressão de desgosto no FER2013), uma baixa revocação evidencia que o modelo falha em detectar aquela categoria, gerando muitos falsos negativos.

A especificidade mede a capacidade do modelo de reconhecer corretamente os exemplos que não pertencem à classe analisada:

$$Specificity_k = \frac{TN_k}{TN_k + FP_k}.$$

O F1-score combina precisão e revocação por meio da média harmônica:

$$F1_k = 2 \cdot \frac{Precision_k \cdot Recall_k}{Precision_k + Recall_k}.$$

A média harmônica penaliza situações em que uma das duas métricas é baixa. Portanto, o F1-score só será elevado quando precisão e revocação forem simultaneamente altas.

Em problemas multiclasse, calculam-se médias das métricas ao longo das K classes. A média macro considera todas as classes com o mesmo peso:

$$Macro\text{-}F1 = \frac{1}{K}\sum_{k=0}^{K-1} F1_k.$$

Já a média ponderada considera a quantidade de exemplos de cada classe:

$$Weighted\text{-}F1 = \sum_{k=0}^{K-1} \frac{n_k}{N} F1_k,$$

em que n_k é o número de exemplos da classe k e N é o número total de exemplos. A média macro é fundamental quando se deseja avaliar se o modelo apresenta desempenho equilibrado em todas as categorias, independentemente de sua frequência amostral, enquanto a média ponderada reflete mais fortemente o desempenho nas classes majoritárias.

Outra métrica relevante em bases desbalanceadas é a acurácia balanceada, definida como a média das revocações por classe:

$$Balanced\ Accuracy = \frac{1}{K}\sum_{k=0}^{K-1} Recall_k.$$

Além dessas métricas, a curva ROC e a AUC (*Area Under the Curve*) podem ser utilizadas para avaliar a capacidade discriminativa do classificador em diferentes limiares de decisão (FAWCETT, 2006; HAND; TILL, 2001). Para cada classe k na formulação *one-vs-rest*, definem-se a taxa de verdadeiros positivos ($TPR_k = \frac{TP_k}{TP_k+FN_k}$) e a taxa de falsos positivos ($FPR_k = \frac{FP_k}{FP_k+TN_k}$), obtendo-se a área sob a curva:

$$AUC_k = \int_0^1 TPR_k(FPR_k)\, dFPR_k.$$

Portanto, a análise conjunta de acurácia, precisão, revocação, Macro-F1 e matriz de confusão oferece uma caracterização rigorosa da capacidade de generalização dos modelos avaliados (DEISENROTH; FAISAL; ONG, 2020).

2.4.5 Seleção de métricas em benchmarks multiclasse e desbalanceados

A avaliação comparativa de modelos ao longo de múltiplos conjuntos de dados exige métricas que sejam simultaneamente sensíveis ao desempenho global e robustas a assimetrias na distribuição de classes. Embora a acurácia global indique a fração total de predições corretas, ela pode mascarar falhas severas em bases fortemente desbalanceadas, como GTSRB, FER2013 e SVHN, nas quais o acerto exclusivo nas classes majoritárias já produz valores elevados de acurácia.

Por esse motivo, este trabalho adota o Macro-F1 como métrica primária de comparação entre arquiteturas, funções de ativação e tamanhos de lote. Por calcular a média não ponderada dos F1-scores de todas as K classes, o Macro-F1 atribui peso idêntico a classes

abundantes e raras, penalizando modelos que colapsam suas predições em poucas categorias. Complementarmente, a inspeção das matrizes de confusão e da variação de F1 por classe (ΔF1) permite diagnosticar em quais categorias visuais específicas ocorrem ganhos ou perdas decorrentes da variação de hiperparâmetros ou da introdução de camadas quânticas.

2.5 Redes neurais e aprendizado profundo

As redes neurais artificiais fazem parte do campo do aprendizado de máquina, no qual modelos computacionais são treinados para reconhecer padrões a partir de dados. Do ponto de vista matemático, um problema de aprendizado supervisionado pode ser representado por um conjunto de exemplos rotulados:

$$\mathcal{D} = \{(x_1, y_1), (x_2, y_2), \ldots, (x_N, y_N)\},$$

em que x_i representa uma entrada e y_i representa o rótulo associado a essa entrada. Em uma tarefa de classificação de imagens nos nove *benchmarks* avaliados, x_i corresponde ao tensor numérico da imagem, enquanto $y_i \in \{0, 1, \ldots, K-1\}$ pertence ao conjunto das K classes definidas no domínio correspondente.

Segundo Deisenroth, Faisal e Ong (2020), a aprendizagem de máquina pode ser compreendida a partir de três componentes principais: dados, modelo e aprendizagem. Os dados precisam ser convertidos para uma representação numérica; o modelo descreve uma função parametrizada; e a aprendizagem corresponde ao ajuste desses parâmetros a partir dos dados disponíveis, com o objetivo de obter bom desempenho em exemplos ainda não vistos.

Assim, um modelo de aprendizado profundo pode ser descrito como uma função parametrizada:

$$f_\theta : \mathbb{R}^D \to \mathbb{R}^K,$$

em que D representa a dimensão da entrada, K representa o número de classes (por exemplo, $K = 7$ no FER2013, $K = 10$ no MNIST, Fashion-MNIST, KMNIST, CIFAR-10 e SVHN, $K = 43$ no GTSRB e $K = 100$ no CIFAR-100) e θ representa o conjunto de parâmetros aprendidos pelo modelo.

O aprendizado profundo, ou *deep learning*, diferencia-se de métodos tradicionais por utilizar múltiplas camadas de transformação não linear. Essas camadas permitem que o modelo aprenda representações hierárquicas dos dados. Em imagens, camadas iniciais tendem a capturar padrões simples, como bordas, contrastes e texturas locais, enquanto camadas mais profundas combinam essas informações em estruturas mais abstratas e semanticamente relevantes (LECUN; BENGIO; HINTON, 2015; GOODFELLOW; BENGIO; COURVILLE, 2016).

Esse processo é essencial quando se avaliam múltiplos domínios visuais sob um mesmo protocolo experimental, pois permite que a mesma estrutura arquitetural adapte seus filtros internos desde contornos geométricos em caracteres manuscritos ($28 \times 28 \times 1$) até padrões cromáticos e texturais complexos em cenas urbanas, sinalização viária e objetos naturais ($32 \times 32 \times 3$).

2.5.1 Redes neurais artificiais

Uma rede neural artificial é composta por unidades matemáticas chamadas neurônios artificiais, organizadas em camadas. Cada neurônio recebe um conjunto de entradas, aplica uma combinação linear desses valores e, em seguida, utiliza uma função de ativação não linear. Considerando uma entrada $x \in \mathbb{R}^D$, uma camada densa pode ser representada por:

$$z = Wx + b,$$

em que $W \in \mathbb{R}^{M \times D}$ é a matriz de pesos, $b \in \mathbb{R}^M$ é o vetor de vieses e $z \in \mathbb{R}^M$ é o vetor de pré-ativações antes da aplicação da função não linear. Após a função de ativação ϕ, obtém-se:

$$h = \phi(z) = \phi(Wx + b).$$

A função de ativação é fundamental porque introduz não linearidade ao modelo. Sem ela, a composição de várias camadas lineares poderia ser reduzida a uma única transformação linear. Além da clássica função ReLU ($\phi(z) = \max(0, z)$), variações modernas como GELU (*Gaussian Error Linear Unit*), SiLU/Swish ($\phi(z) = z \cdot \sigma(z)$), ELU (*Exponential Linear Unit*) e LeakyReLU modificam a curvatura e o regime de propagação de gradientes para valores negativos de z. A escolha comparativa entre essas funções de ativação desempenha papel central na campanha experimental deste trabalho, uma vez que impacta diretamente tanto a estabilidade de convergência e o Macro-F1 final quanto o custo aritmético de execução entre plataformas distintas (Windows e macOS).

Em uma rede com múltiplas camadas, a saída de uma camada é utilizada como entrada da camada seguinte. Assim, para uma camada l, tem-se:

$$h^{(l)} = \phi\left(W^{(l)} h^{(l-1)} + b^{(l)}\right),$$

em que $h^{(l-1)}$ representa a saída da camada anterior, $W^{(l)}$ a matriz de pesos da camada atual e $b^{(l)}$ o vetor de vieses. O conjunto de todos os pesos e vieses da rede compõe os parâmetros θ.

Em tarefas de classificação multiclasse, a última camada geralmente produz um vetor de escores $s \in \mathbb{R}^K$, em que cada componente corresponde a uma classe. Para transformar esses escores em probabilidades, utiliza-se a função *softmax*:

$$p_k = \frac{e^{s_k}}{\sum_{j=0}^{K-1} e^{s_j}},$$

em que p_k representa a probabilidade estimada para a classe k. A classe prevista é dada por:

$$\hat{y} = \arg\max_k p_k.$$

O treinamento da rede consiste em ajustar os parâmetros θ para reduzir a diferença entre a saída prevista e o rótulo verdadeiro. Para isso, define-se uma função de perda. Em problemas de classificação multiclasse, uma escolha comum é a entropia cruzada categórica:

$$\mathcal{L}(y, \hat{p}) = -\sum_{k=0}^{K-1} y_k \log(p_k),$$

em que y_k representa o rótulo verdadeiro em codificação *one-hot*. O objetivo do treinamento pode ser expresso como a minimização do risco empírico:

$$R_{\text{emp}}(\theta) = \frac{1}{N} \sum_{i=1}^{N} \mathcal{L}(y_i, f_\theta(x_i)).$$

A atualização dos parâmetros é feita por métodos de otimização baseados em gradiente. De forma simplificada, uma etapa de gradiente descendente pode ser escrita como:

$$\theta_{t+1} = \theta_t - \eta \nabla_\theta R_{\text{emp}}(\theta_t),$$

em que η é a taxa de aprendizado e $\nabla_\theta R_{\text{emp}}$ representa o gradiente da função de perda em relação aos parâmetros. Esse processo mostra que redes neurais dependem diretamente de fundamentos matemáticos como álgebra linear, cálculo vetorial, probabilidade e otimização (DEISENROTH; FAISAL; ONG, 2020).

O cálculo dos gradientes em redes profundas é realizado por meio da retropropagação do erro, ou *backpropagation*. Esse algoritmo utiliza a regra da cadeia para calcular a contribuição de cada parâmetro para o erro final, permitindo que os pesos sejam atualizados progressivamente durante o treinamento. Assim, a rede aprende uma transformação capaz de mapear entradas numéricas para classes de saída.

2.5.2 Redes neurais convolucionais

As redes neurais convolucionais, ou CNNs (*Convolutional Neural Networks*), são arquiteturas especializadas no processamento de dados com estrutura espacial, como imagens. Diferentemente das redes densas, nas quais todos os neurônios de uma camada se conectam a todos os neurônios da camada seguinte, as CNNs exploram a organização local dos pixels por meio de filtros convolucionais. Essa característica reduz o número

de parâmetros, preserva relações espaciais e permite que a rede aprenda padrões visuais relevantes diretamente a partir dos dados.

Em uma imagem digital, pixels vizinhos geralmente possuem relações importantes entre si. Bordas, texturas, contrastes, contornos geométricos e estruturas locais não aparecem como valores isolados, mas como padrões distribuídos em regiões vizinhas da imagem. Por esse motivo, as CNNs são especialmente adequadas para tarefas de visão computacional, pois aplicam filtros sobre pequenas janelas da imagem, extraindo informações locais que são combinadas progressivamente ao longo das camadas.

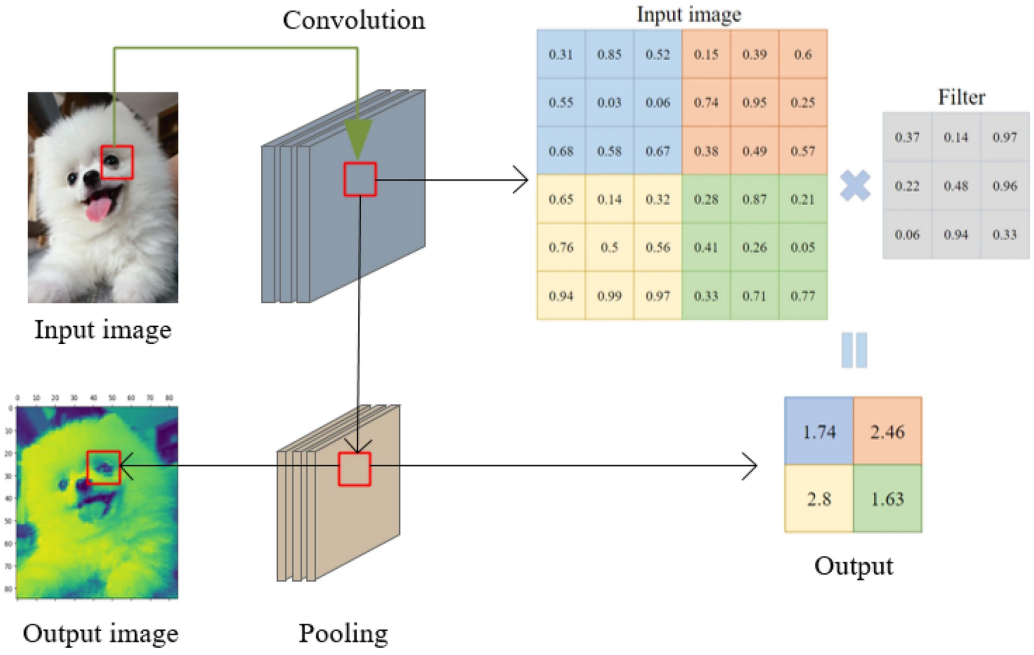
Matematicamente, uma convolução discreta pode ser entendida como a aplicação de um filtro, ou *kernel*, sobre uma imagem. Considerando uma imagem bidimensional I e um filtro K de tamanho $(2a+1) \times (2b+1)$, a saída da convolução em uma posição (i, j) pode ser representada por:

$$S(i,j) = \sum_{m=-a}^{a} \sum_{n=-b}^{b} K(m,n) \cdot I(i+m, j+n).$$

Nessa expressão, $I(i+m, j+n)$ representa os pixels vizinhos à posição analisada, enquanto $K(m,n)$ representa os pesos do filtro. O resultado $S(i,j)$ corresponde à resposta do filtro naquela região da imagem. Assim, cada posição do mapa de saída resume uma combinação ponderada de uma vizinhança local da imagem original.

A Figura 2 apresenta uma representação esquemática da aplicação de um filtro convolucional sobre uma imagem e da etapa posterior de *pooling*. A convolução percorre a imagem por regiões locais e produz um mapa de características; em seguida, o *pooling* reduz a dimensão espacial desse mapa, preservando informações consideradas mais relevantes.

Figura 2 – Representação esquemática das operações de convolução e *pooling* em uma rede neural convolucional.



Fonte: adaptado de Zhao e Zhang (ZHAO; ZHANG, 2024).

Em uma CNN, os valores dos filtros não são definidos manualmente. Eles são aprendidos durante o treinamento, de acordo com a função de perda e com os dados apresentados à rede. Nas primeiras camadas, os filtros tendem a capturar padrões simples, como bordas, contornos, regiões de contraste e texturas. Nas camadas intermediárias e profundas, esses padrões são combinados em representações mais complexas, capazes de descrever estruturas maiores e mais abstratas.

Em uma camada convolucional, vários filtros são aplicados sobre a imagem ou sobre os mapas de características produzidos pela camada anterior. Cada filtro gera um mapa de características diferente, destacando um tipo de padrão visual. Para uma entrada com múltiplos canais, a saída de um filtro r pode ser escrita como:

$$S_r(i,j) = \sum_{c=1}^{C} \sum_{m=-a}^{a} \sum_{n=-b}^{b} K_{r,c}(m,n) \cdot I_c(i+m, j+n) + b_r,$$

em que C é o número de canais de entrada, r identifica o filtro utilizado, $K_{r,c}$ representa os pesos do filtro r aplicados ao canal c, e b_r é o viés associado ao filtro. Em bases coloridas no formato RGB (como CIFAR-10, CIFAR-100, SVHN e GTSRB), tem-se $C = 3$. Já em bases monocromáticas em escala de cinza (como MNIST, Fashion-MNIST, KMNIST, EMNIST e FER2013), tem-se $C = 1$, pois há apenas um canal de intensidade.

Após a convolução, aplica-se normalmente uma função de ativação não linear, como a ReLU (*Rectified Linear Unit*):

$$ReLU(x) = \max(0, x).$$

Essa função mantém valores positivos e zera valores negativos, introduzindo não linearidade ao modelo. Sem funções de ativação, a composição de várias camadas convolucionais e densas poderia ser reduzida a uma transformação linear, limitando a capacidade da rede de representar padrões complexos.

Depois da ativação, é comum utilizar uma camada de *pooling*. O *pooling* reduz a dimensão espacial dos mapas de características, diminuindo o custo computacional e tornando a representação mais compacta. Uma operação comum é o *max pooling*, definida por:

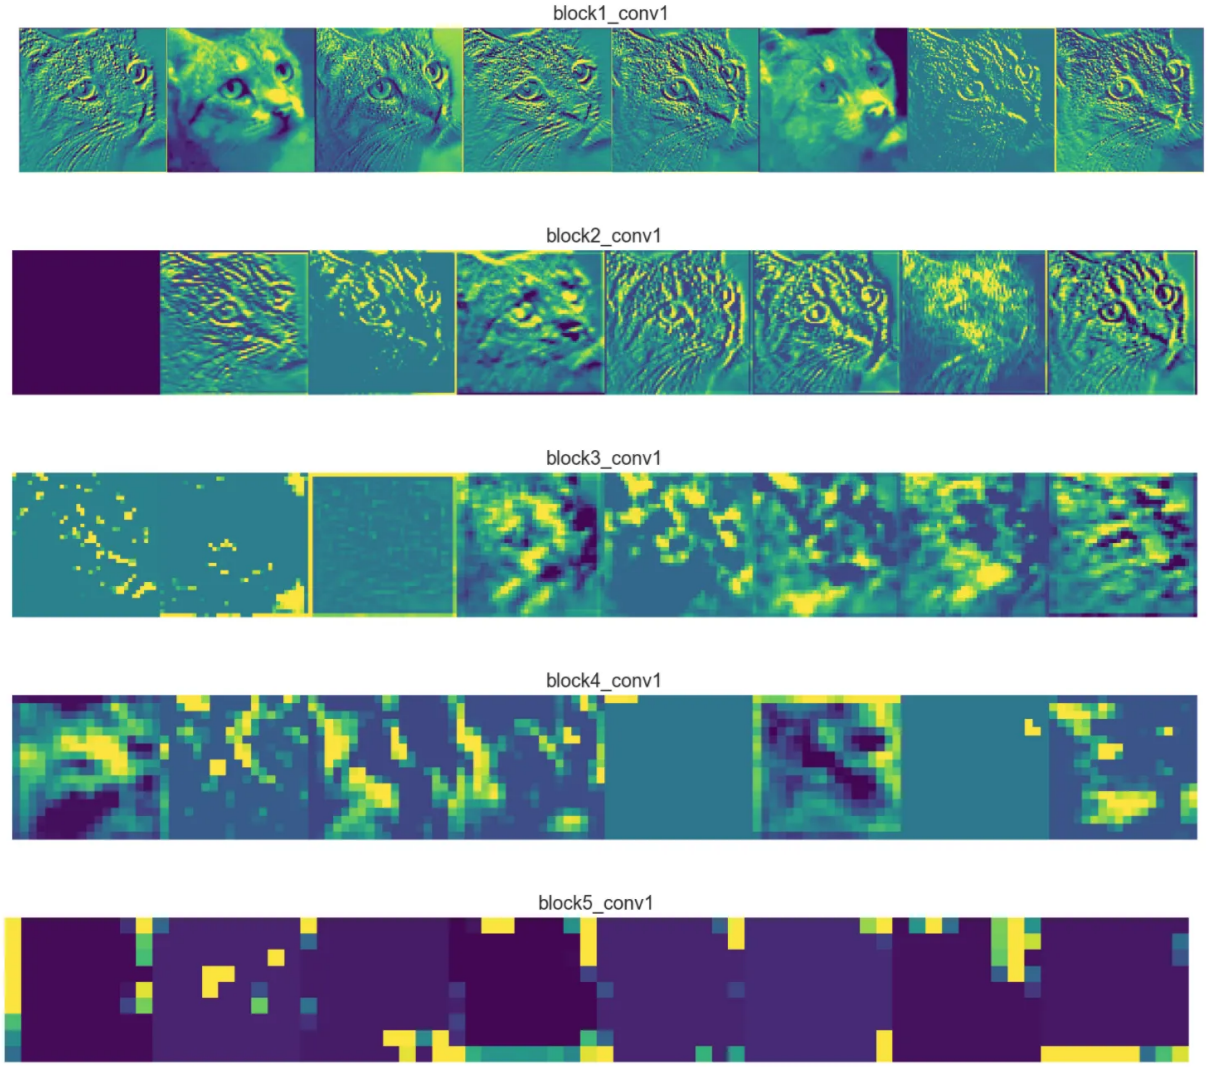
$$P(i, j) = \max_{(m,n)\in R_{ij}} S(m, n),$$

em que R_{ij} representa uma região local do mapa de características. Nesse caso, a saída corresponde ao maior valor dentro da janela analisada. Também existe o *average pooling*, que calcula a média dos valores da região. Zhao e Zhang (2024) destacam que o *pooling* é importante para reduzir as dimensões espaciais e o volume de dados, mas também pode causar perda de informações, especialmente quando detalhes finos são relevantes.

Esse ponto é particularmente importante em *benchmarks* de baixa resolução espacial (28×28 ou 32×32 pixels). Reduções espaciais excessivas podem suprimir traços caligráficos sutis no KMNIST e EMNIST, pequenos elementos de sinalização no GTSRB ou microexpressões faciais no FER2013. Portanto, a profundidade e o escalonamento espacial dos blocos convolucionais devem equilibrar compressão e preservação de detalhes discriminativos.

A Figura 3 mostra uma visualização de mapas de características produzidos em diferentes blocos convolucionais. Observa-se que as primeiras camadas ainda preservam boa parte da estrutura visual da imagem original, enquanto camadas mais profundas produzem ativações mais abstratas e espacialmente reduzidas. Esse comportamento ilustra a ideia de aprendizado hierárquico em CNNs: padrões simples são aprendidos nas camadas iniciais e combinados em representações mais complexas nas camadas posteriores.

Figura 3 – Exemplo de visualização de mapas de características em diferentes blocos convolucionais. As camadas iniciais tendem a preservar bordas, texturas e contornos, enquanto camadas mais profundas representam padrões mais abstratos.



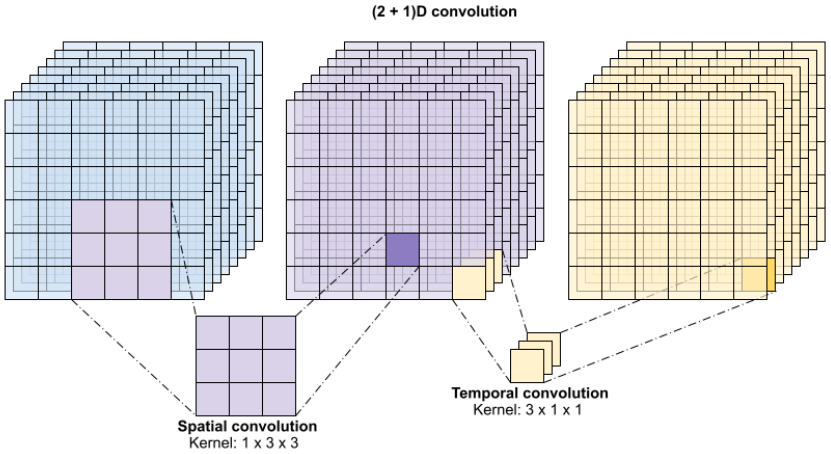
Fonte: adaptado de Hesaraki (HESARAKI, 2023).

O desenvolvimento das CNNs profundas foi fundamental para o avanço da visão computacional. Arquiteturas como AlexNet, VGG, GoogLeNet/Inception e ResNet demonstraram que redes convolucionais profundas podem aprender representações hierárquicas altamente eficazes para classificação de imagens (SZEGEDY et al., 2015; HE et al., 2016). Szegedy et al. (2015) mostraram que é possível aumentar profundidade e largura da rede mantendo preocupação com eficiência computacional, princípio essencial em campanhas experimentais extensas envolvendo múltiplos conjuntos de dados.

A Figura 4 apresenta uma decomposição de convolução espaço-temporal em uma convolução espacial e uma convolução temporal. Embora este trabalho utilize imagens estáticas bidimensionais nos nove conjuntos de dados avaliados, e não sequências temporais, a figura ilustra como diferentes operadores convolucionais podem ser estruturados de acordo com a dimensionalidade do sinal. Em imagens 2D, o filtro percorre altura e largura; em

dados volumétricos ou sequenciais, a convolução incorpora também profundidade ou tempo.

Figura 4 – Exemplo de decomposição de uma convolução espaço-temporal em convolução espacial e temporal. No contexto deste trabalho, a figura ilustra a generalidade do operador convolucional, sendo os nove *benchmarks* avaliados compostos por imagens estáticas bidimensionais.



Fonte: Elaborado pelo autor (2026).

Dessa forma, a estrutura canônica de uma CNN combina camadas convolucionais, normalização em lote (*batch normalization*), funções de ativação não lineares, camadas de *pooling*, regularização por *dropout* e uma cabeça de classificação que mapeia as características extraídas para a distribuição de probabilidades entre as K classes do problema.

2.5.3 CNNs aplicadas a múltiplos domínios de visão computacional e eficiência de execução

As redes neurais convolucionais consolidaram-se como a arquitetura de referência para classificação de imagens em múltiplos domínios devido ao compartilhamento de pesos e à invariância local a translações. Ao aplicar filtros convolucionais sucessivos seguidos de funções de ativação não lineares e operações de redução espacial (*pooling*), a rede adapta seus mapas de características tanto a traços morfológicos simples em imagens monocromáticas ($28 \times 28 \times 1$) quanto a texturas cromáticas complexas em imagens naturais ($32 \times 32 \times 3$).

Além da topologia das camadas, o comportamento prático de uma CNN em campanhas extensas de treinamento é fortemente influenciado pelo dimensionamento do lote (*batch size*) e pela precisão numérica dos parâmetros. Lotes menores (como 32 ou 64) introduzem maior variância estocástica na estimativa do gradiente, o que pode atuar como regularizador implícito e favorecer a generalização em determinadas bases, porém reduz o paralelismo de hardware e eleva o tempo por época. Em contrapartida, lotes maiores (como 128 ou 256) maximizam a taxa de processamento (*throughput*) em GPUs, mas podem convergir para

mínimos mais agudos caso a taxa de aprendizado não seja devidamente ajustada. De modo complementar, técnicas de quantização de modelos permitem comprimir a representação numérica dos pesos e ativações (por exemplo, de ponto flutuante de 32 bits para inteiros de 8 bits ou ponto flutuante de 16 bits), buscando reduzir a latência de inferência e o uso de memória sem degradação significativa no Macro-F1 (GOODFELLOW; BENGIO; COURVILLE, 2016; ZANDIEH et al., 2025).

2.5.4 Aumento de dados, regularização e overfitting

O treinamento de redes neurais profundas exige cuidado com a capacidade de generalização do modelo. Em aprendizado supervisionado, o objetivo não é apenas reduzir o erro sobre os dados de treinamento, mas obter bom desempenho em exemplos ainda não vistos. Esse princípio é especialmente relevante quando se avaliam bases com alto número de classes ou forte desbalanceamento, pois modelos de alta capacidade podem memorizar padrões de fundo, artefatos de iluminação ou peculiaridades amostrais do conjunto de treino.

Em termos matemáticos, considera-se um conjunto de treinamento:

$$\mathcal{D}_{train} = \{(x_1, y_1), (x_2, y_2), \ldots, (x_N, y_N)\},$$

em que x_i representa uma imagem e y_i seu respectivo rótulo. O treinamento busca ajustar os parâmetros θ de um modelo f_θ minimizando uma função de perda média, também chamada de risco empírico:

$$R_{\text{emp}}(\theta) = \frac{1}{N} \sum_{i=1}^{N} \mathcal{L}(y_i, f_\theta(x_i)).$$

Entretanto, minimizar excessivamente essa perda no conjunto de treino não garante bom desempenho em dados novos. Quando o modelo apresenta baixo erro no treino, mas erro elevado na validação ou no teste, ocorre o fenômeno conhecido como *overfitting*, ou sobreajuste. Nesse caso, a rede aprende detalhes específicos dos exemplos de treinamento, reduzindo sua capacidade de generalização. Por outro lado, quando o modelo é simples demais ou treinado de forma insuficiente, pode ocorrer *underfitting*, situação em que o desempenho é baixo tanto no treino quanto na validação.

Uma forma de reduzir o sobreajuste é aplicar regularização. A regularização introduz restrições ou penalizações ao processo de aprendizagem, buscando impedir que o modelo se ajuste de forma excessiva aos dados de treino. Uma formulação comum consiste em adicionar um termo de penalização à função objetivo:

$$J(\theta) = \frac{1}{N} \sum_{i=1}^{N} \mathcal{L}(y_i, f_\theta(x_i)) + \lambda \Omega(\theta),$$

em que $\Omega(\theta)$ é o termo de regularização e λ controla a intensidade da penalização. Quando se utiliza regularização L_2 (*weight decay*), por exemplo, a penalização é definida como:

$$\Omega(\theta) = \|\theta\|_2^2.$$

Nesse caso, pesos muito altos são penalizados, incentivando o modelo a encontrar soluções mais suaves e menos dependentes de parâmetros extremos. Essa estratégia pode melhorar a generalização, pois reduz a tendência da rede de memorizar detalhes específicos dos dados de treino (GOODFELLOW; BENGIO; COURVILLE, 2016).

Outra técnica amplamente utilizada é o *dropout*. Durante o treinamento, o *dropout* desativa aleatoriamente uma proporção dos neurônios de uma camada, forçando a rede a distribuir melhor a informação entre diferentes unidades. Se h representa o vetor de ativações de uma camada, o *dropout* pode ser representado de forma simplificada como:

$$\tilde{h} = m \odot h,$$

em que m é uma máscara binária aleatória, $\odot$ representa o produto elemento a elemento e $\tilde{h}$ corresponde às ativações após a aplicação da máscara. Essa técnica reduz a dependência excessiva de neurônios específicos e contribui para tornar o modelo mais robusto.

Além da regularização dos parâmetros, outra estratégia essencial é o aumento de dados, ou *data augmentation*. Essa técnica consiste em gerar variações artificiais das imagens de treinamento por meio de transformações que preservam o rótulo da amostra. Matematicamente, uma imagem x_i pode ser transformada por uma função T, produzindo uma nova amostra:

$$x_i' = T(x_i),$$

em que x_i' mantém o mesmo rótulo y_i, desde que a transformação respeite a semântica da classe.

No contexto de *benchmarks* heterogêneos de visão computacional, a estratégia de aumento de dados (*data augmentation*) deve respeitar as invariâncias semânticas de cada domínio. Enquanto pequenos deslocamentos horizontais/verticais, recortes aleatórios (*random crops*) e rotações leves preservam o rótulo na maioria das bases, espelhamentos horizontais (*horizontal flips*) são válidos para objetos naturais (CIFAR-10/100), artigos de vestuário simétricos e faces (FER2013), mas inválidos para dígitos, caracteres e determinadas placas de trânsito (MNIST, KMNIST, EMNIST, SVHN e GTSRB), pois inverteriam a orientação canônica do símbolo. Assim, o controle experimental entre regimes sem aumento de dados e com aumento controlado é fundamental para isolar o ganho real de regularização em cada arquitetura.

Outra técnica relacionada à regularização é o *early stopping*. Nesse procedimento, o desempenho do modelo é monitorado no conjunto de validação durante o treinamento. Quando a perda de validação (ou o Macro-F1 de validação) deixa de melhorar por um número definido de épocas, o treinamento é interrompido ou o melhor *checkpoint* é restaurado. Essa estratégia evita que o modelo continue reduzindo a perda de treino enquanto degrada sua capacidade de generalização:

$$\mathcal{L}_{train} \downarrow \quad \text{e} \quad \mathcal{L}_{val} \uparrow .$$

Portanto, aumento de dados controlado por domínio, regularização L_2, *dropout*, normalização em lote e seleção pelo melhor estado de validação constituem estratégias complementares indispensáveis para garantir estabilidade e reprodutibilidade ao comparar modelos clássicos e híbridos nos nove conjuntos de dados.

2.5.5 Explicabilidade e interpretação de representações em CNNs

A interpretabilidade das representações internas aprendidas por redes neurais profundas é um aspecto relevante em visão computacional, uma vez que permite auditar se as decisões de um classificador baseiam-se em atributos morfológicos legítimos do objeto ou em correlações espúrias do fundo da imagem. Embora CNNs alcancem elevado desempenho preditivo, suas decisões resultam da composição de múltiplas camadas de transformação não linear.

Uma das técnicas utilizadas para auxiliar a inspeção espacial de CNNs é o Grad-CAM (*Gradient-weighted Class Activation Mapping*) (SELVARAJU et al., 2020). Essa abordagem gera mapas de ativação ponderados por gradientes que destacam quais regiões espaciais da imagem exerceram maior influência na predição de determinada classe k. Em *benchmarks* de visão computacional, análises de mapas de características e de atenção espacial complementam a inspeção de matrizes de confusão e de resíduos por classe (ΔF1), auxiliando a compreender como diferentes escolhas arquiteturais e de hiperparâmetros afetam a extração de padrões visuais.

2.6 Computação quântica e aprendizado de máquina quântico

A computação quântica é um paradigma computacional baseado em princípios da mecânica quântica, como superposição, emaranhamento, interferência e medição probabilística (NIELSEN; CHUANG, 2010). Diferentemente da computação clássica, que utiliza bits para representar informações nos estados 0 ou 1, a computação quântica utiliza qubits, que podem assumir combinações lineares desses estados. Essa diferença permite representar e manipular informações em espaços vetoriais complexos de alta dimensão, chamados espaços de Hilbert.

O aprendizado de máquina quântico, ou *Quantum Machine Learning* (QML), investiga como recursos da computação quântica podem ser utilizados em tarefas de aprendizado de máquina, como classificação, regressão, agrupamento e redução de dimensionalidade. Em dispositivos quânticos atuais, caracterizados por número limitado de qubits, ruído e restrições de profundidade dos circuitos, uma das abordagens mais estudadas é a construção de modelos híbridos quântico-clássicos. Nesses modelos, parte do processamento é realizada por componentes clássicos e parte por circuitos quânticos parametrizados (BIAMONTE et al., 2017; PRESKILL, 2018; CEREZO et al., 2021).

No contexto deste trabalho, o interesse principal está na aplicação de modelos híbridos à classificação supervisionada de imagens ao longo de múltiplos *benchmarks* de visão computacional. Como mesmo imagens compactas possuem centenas ou milhares de valores de intensidade, a aplicação direta de circuitos quânticos a todos os pixels ainda é limitada. Por isso, arquiteturas híbridas utilizam camadas convolucionais clássicas para extrair e comprimir características espaciais e, posteriormente, inserem um bloco quântico variacional responsável por processar esse vetor latente antes da camada final de decisão.

2.6.1 Qubits, superposição, emaranhamento e medição

O qubit é a unidade básica de informação quântica. Enquanto um bit clássico pode assumir apenas um dos valores 0 ou 1, um qubit pode ser representado como uma combinação linear dos estados base $|0\rangle$ e $|1\rangle$:

$$|\psi\rangle = \alpha\,|0\rangle + \beta\,|1\rangle\,,$$

em que α e β são amplitudes complexas que satisfazem a condição de normalização:

$$|\alpha|^2 + |\beta|^2 = 1.$$

Os valores $|\alpha|^2$ e $|\beta|^2$ representam as probabilidades de observar, após a medição, os estados $|0\rangle$ e $|1\rangle$, respectivamente. Assim, antes da medição, o qubit pode estar em superposição; após a medição, o resultado observado será clássico, assumindo um dos estados possíveis.

Para um sistema com n qubits, o estado quântico pertence a um espaço de dimensão 2^n. Por exemplo, dois qubits possuem quatro estados base:

$$|00\rangle\,, |01\rangle\,, |10\rangle\,, |11\rangle\,.$$

De forma geral, um estado de dois qubits pode ser representado por:

$$|\psi\rangle = \alpha_{00}\,|00\rangle + \alpha_{01}\,|01\rangle + \alpha_{10}\,|10\rangle + \alpha_{11}\,|11\rangle\,,$$

com a condição:

$$|\alpha_{00}|^2 + |\alpha_{01}|^2 + |\alpha_{10}|^2 + |\alpha_{11}|^2 = 1.$$

Esse crescimento exponencial do espaço de estados é uma das razões pelas quais a computação quântica desperta interesse em problemas de alta complexidade. Entretanto, esse mesmo crescimento também torna a simulação clássica de circuitos quânticos rapidamente custosa.

Outro fenômeno importante é o emaranhamento. Um estado é dito emaranhado quando não pode ser decomposto como produto tensorial de estados individuais dos qubits. Um exemplo clássico é o estado de Bell:

$$|\Phi^+\rangle = \frac{1}{\sqrt{2}}(|00\rangle + |11\rangle).$$

Nesse caso, os qubits apresentam correlações que não podem ser descritas apenas como estados independentes. A medição de um qubit afeta a descrição do estado global do sistema, produzindo correlações probabilísticas fortes entre os resultados.

A medição é o processo que transforma informação quântica em informação clássica. Em modelos de aprendizado de máquina quântico, as medições são fundamentais, pois as saídas do circuito geralmente são obtidas por probabilidades de medição ou por valores esperados de observáveis. Por exemplo, pode-se medir o valor esperado do operador de Pauli-Z em um qubit:

$$\langle Z \rangle = \langle \psi | \, Z \, | \psi \rangle \, .$$

Esse valor esperado pode ser utilizado como uma característica numérica de saída do circuito quântico e, posteriormente, alimentar uma camada clássica de classificação.

2.6.2 Portas e circuitos quânticos parametrizados

As portas quânticas são operações matemáticas aplicadas sobre qubits. Diferentemente de muitas operações clássicas, as portas quânticas são representadas por matrizes unitárias, isto é, matrizes U que satisfazem:

$$U^\dagger U = I,$$

em que $U^\dagger$ representa a conjugada transposta de U e I é a matriz identidade. Essa propriedade garante que a norma do estado quântico seja preservada durante a evolução do circuito.

Entre as portas quânticas mais comuns estão as portas de Pauli X, Y e Z, a porta Hadamard H, portas de rotação e portas controladas, como CNOT e CZ. A porta Hadamard, por exemplo, é frequentemente utilizada para criar superposição:

$$H\,|0\rangle = \frac{1}{\sqrt{2}}(|0\rangle + |1\rangle).$$

Portas de rotação são especialmente importantes em modelos variacionais, pois dependem de parâmetros ajustáveis. Uma rotação em torno do eixo Y, por exemplo, pode ser representada por:

$$R_Y(\theta) = e^{-i\frac{\theta}{2}Y}.$$

De modo geral, um circuito quântico parametrizado pode ser representado por uma operação unitária $U(\theta)$, em que θ representa um conjunto de parâmetros treináveis. Um circuito formado por várias camadas pode ser escrito como:

$$U(\theta) = U_L(\theta_L)U_{L-1}(\theta_{L-1})\cdots U_1(\theta_1).$$

Essa estrutura é análoga, em certo sentido, às redes neurais clássicas, nas quais diferentes camadas aplicam transformações sucessivas aos dados. No caso quântico, as transformações são operações unitárias aplicadas sobre estados quânticos.

Em modelos híbridos, os parâmetros do circuito são ajustados por um otimizador clássico. O circuito quântico calcula uma saída, normalmente associada a valores esperados de observáveis, e essa saída é usada para computar uma função de custo. Em seguida, um algoritmo clássico atualiza os parâmetros do circuito. Esse ciclo forma a base dos algoritmos variacionais quânticos (CEREZO et al., 2021).

2.6.3 Codificação de dados clássicos em estados quânticos

Para que dados clássicos sejam processados por um circuito quântico, é necessário convertê-los em estados quânticos ou em parâmetros de portas quânticas. Esse processo é chamado de codificação, incorporação ou *embedding* dos dados (SCHULD; SWEKE; MEYER, 2021). A escolha da codificação é uma etapa central em QML, pois determina como a informação clássica será representada no espaço quântico.

Uma forma simples de codificação é a codificação por ângulo (*angle embedding*). Nesse caso, os atributos clássicos de uma entrada $x = [x_1, x_2, \ldots, x_d]$ são usados como ângulos de rotação em portas quânticas. Por exemplo, pode-se aplicar uma rotação em cada qubit:

$$|\psi(x)\rangle = \prod_{j=1}^{d} R_Y(x_j)\,|0\rangle^{\otimes n}.$$

Essa estratégia é simples e adequada para circuitos rasos, mas exige que a dimensão dos dados seja compatível com o número de qubits ou com o número de portas utilizadas. Em tarefas de visão computacional, esse ponto torna-se determinante, pois até mesmo imagens compactas de *benchmarks* padronizados contêm entre 784 e 3.072 valores de entrada, número muito superior à quantidade de qubits viável em simuladores atuais.

Outra abordagem é o uso de *quantum feature maps*. Nesse caso, os dados clássicos são mapeados para estados quânticos por meio de um circuito $U_\Phi(x)$, produzindo:

$$|\Phi(x)\rangle = U_\Phi(x)\,|0\rangle^{\otimes n}\,.$$

A motivação é que o espaço de Hilbert pode atuar como um espaço de características de alta dimensão. Havlíček et al. (2019) propuseram métodos de aprendizado supervisionado com espaços de características quânticos, incluindo classificadores variacionais e estimadores de kernel quântico. A ideia central é mapear os dados clássicos de forma não linear para estados quânticos e explorar produtos internos nesse espaço para realizar classificação.

Em métodos baseados em kernel, a similaridade entre duas entradas x e z pode ser calculada por:

$$K(x,z) = |\langle\Phi(x)|\Phi(z)\rangle|^2.$$

Essa formulação estabelece uma conexão direta entre QML e métodos clássicos como SVMs, nos quais a escolha do kernel influencia fortemente a capacidade de separação entre classes.

Uma limitação relevante da codificação é que dados clássicos não podem ser simplesmente copiados dentro de um circuito quântico como ocorre em redes neurais clássicas. Para contornar parte dessa limitação, Pérez-Salinas et al. (2020) propuseram a técnica de *data re-uploading*, na qual os mesmos dados clássicos são inseridos repetidas vezes ao longo do circuito. Um circuito com reenvio de dados pode ser representado de forma simplificada como:

$$U(\theta,x) = L_N(\theta_N,x)\cdots L_2(\theta_2,x)L_1(\theta_1,x),$$

em que cada camada L_i combina parâmetros treináveis e dados de entrada. Essa técnica aumenta a capacidade expressiva do circuito, permitindo que modelos com poucos qubits representem funções mais complexas.

No contexto de classificação de imagens, como o número de pixels em bases $28 \times 28 \times 1$ (784 valores), $48 \times 48 \times 1$ (2.304 valores) ou $32 \times 32 \times 3$ (3.072 valores) inviabiliza a alocação de um qubit por pixel, modelos híbridos empregam um extrator convolucional clássico para comprimir a imagem em um vetor latente de baixa dimensão antes da etapa de codificação quântica.

2.6.4 Modelos variacionais quânticos

Modelos variacionais quânticos são uma das principais abordagens para uso de computação quântica em dispositivos NISQ. Esses modelos combinam circuitos quânticos parametrizados com otimizadores clássicos. O circuito quântico é responsável por preparar

estados, aplicar transformações e produzir medições; o computador clássico calcula a função de custo e atualiza os parâmetros do circuito.

A estrutura geral de um algoritmo variacional pode ser descrita por três componentes: uma função de custo $C(\theta)$, um circuito parametrizado, também chamado de *ansatz*, e um otimizador clássico. O objetivo é encontrar os parâmetros:

$$\theta^* = \arg\min_{\theta} C(\theta).$$

A função de custo pode depender de medições realizadas no circuito quântico. Em muitos casos, ela pode ser expressa em termos de valores esperados de observáveis:

$$C(\theta) = \sum_k f_k \left(\mathrm{Tr}[O_k U(\theta) \rho_k U^\dagger(\theta)] \right),$$

em que O_k representa um observável, ρ_k representa um estado de entrada e $U(\theta)$ é o circuito parametrizado. Essa formulação mostra como o circuito quântico e o otimizador clássico atuam em conjunto no processo de aprendizagem (CEREZO et al., 2021).

Em classificação, o circuito pode receber uma entrada codificada x, aplicar uma transformação variacional e produzir saídas por medição. Por exemplo:

$$z_j(x, \theta) = \langle Z_j \rangle = \langle \psi(x, \theta) | \, Z_j \, | \psi(x, \theta) \rangle .$$

O vetor $z(x, \theta)$ pode ser utilizado diretamente para classificação ou enviado a uma camada clássica, como uma camada densa com ativação *softmax*. Assim, o circuito quântico atua como uma camada treinável dentro de um *pipeline* maior.

A escolha do *ansatz* é uma decisão importante. Um *ansatz* muito simples pode não ter capacidade suficiente para representar padrões complexos; por outro lado, um *ansatz* muito profundo pode ser difícil de treinar e mais sensível a ruído. Essa tensão entre expressividade, profundidade, número de qubits e treinabilidade é uma das principais questões em modelos variacionais quânticos.

2.6.5 Limitações de simulação, barren plateaus e escalabilidade

Apesar do potencial dos modelos quânticos, sua aplicação prática ainda enfrenta limitações importantes. A primeira delas é o custo de simulação. Um sistema com n qubits possui 2^n amplitudes complexas. Assim, a memória necessária para simular exatamente um estado quântico cresce exponencialmente com o número de qubits. Essa limitação é especialmente relevante em pesquisas executadas em computadores clássicos, nas quais o aumento do número de qubits rapidamente se torna inviável.

Outro desafio é a presença de *barren plateaus*. Esse termo descreve regiões da paisagem de otimização nas quais os gradientes da função de custo se tornam muito pequenos. Quando isso ocorre, o otimizador clássico tem dificuldade para encontrar direções úteis

de atualização dos parâmetros. McClean et al. (2018) demonstraram que, para certas famílias de circuitos quânticos parametrizados, a variância dos gradientes pode decair exponencialmente com o número de qubits.

De forma simplificada, se $E(\theta)$ representa uma função de custo, o treinamento depende de gradientes como:

$$\frac{\partial E(\theta)}{\partial \theta_k}.$$

Em um *barren plateau*, esses gradientes se aproximam de zero para grande parte do espaço de parâmetros:

$$\frac{\partial E(\theta)}{\partial \theta_k} \approx 0.$$

Isso dificulta o treinamento, pois as atualizações de parâmetros tornam-se pouco informativas. Em contraste com redes neurais clássicas, nas quais o desaparecimento do gradiente costuma estar fortemente associado à profundidade da rede, em circuitos quânticos o problema também pode depender fortemente do número de qubits e da forma do *ansatz*.

A escalabilidade também é limitada pelo ruído dos dispositivos NISQ. Circuitos mais profundos tendem a acumular mais erros, e circuitos com muitos qubits exigem maior conectividade e controle físico. Por isso, modelos híbridos atuais costumam utilizar poucos qubits e circuitos relativamente rasos. Essa escolha melhora a viabilidade prática, mas também pode limitar a expressividade do componente quântico.

Em problemas de classificação visual multiclasse, essas limitações exigem redução dimensional prévia por camadas clássicas. Portanto, qualquer comparação entre modelos clássicos e híbridos deve considerar não apenas métricas preditivas, mas também telemetria de tempo de treinamento, estabilidade de convergência, uso de memória e viabilidade de simulação.

2.7 Modelos híbridos quântico-clássicos

Modelos híbridos quântico-clássicos combinam componentes de aprendizado de máquina clássico com circuitos quânticos parametrizados. Essa abordagem é adequada ao cenário NISQ porque permite utilizar circuitos pequenos, enquanto delega ao computador clássico tarefas como pré-processamento, extração de características, otimização e classificação final.

Em tarefas de classificação de imagens, uma estratégia comum é usar uma rede neural clássica, especialmente uma CNN, para extrair características visuais da imagem. Em seguida, essas características são projetadas para uma dimensão compatível com o número de qubits e codificadas em um circuito quântico. O circuito atua como uma

camada variacional ou transformadora, e suas saídas são processadas por camadas clássicas responsáveis pela classificação final.

Essa estrutura permite investigar se o componente quântico contribui para a representação dos dados ou para a separação entre classes. No entanto, a simples inclusão de um circuito quântico não garante ganho de desempenho. A contribuição do bloco quântico precisa ser avaliada de forma controlada, comparando-o com *baselines* clássicos equivalentes.

2.7.1 Modelos híbridos quântico-clássicos para classificação

Em um modelo híbrido para classificação, o fluxo geral pode ser descrito por quatro etapas. A primeira é o processamento clássico da entrada. Considerando uma imagem x, uma rede clássica g_ϕ pode extrair um vetor de características:

$$v = g_\phi(x),$$

em que ϕ representa os parâmetros da rede clássica. Em seguida, esse vetor é projetado para uma dimensão menor, compatível com o número de qubits:

$$u = Wv + b.$$

O vetor u é então codificado em um circuito quântico por meio de um operador de codificação $U_{\text{enc}}(u)$, produzindo um estado:

$$|\psi(u)\rangle = U_{\text{enc}}(u)\,|0\rangle^{\otimes n}.$$

Depois, aplica-se um circuito variacional $U(\theta)$, cujos parâmetros são treináveis:

$$|\psi(u,\theta)\rangle = U(\theta)U_{\text{enc}}(u)\,|0\rangle^{\otimes n}.$$

A saída do circuito pode ser obtida por valores esperados de observáveis, como operadores de Pauli-Z:

$$z_j = \langle\psi(u,\theta)|\,Z_j\,|\psi(u,\theta)\rangle.$$

Esses valores formam um vetor z, que pode ser enviado a uma camada clássica final:

$$\hat{y} = \text{softmax}(W_c z + b_c).$$

Essa formulação mostra que o circuito quântico pode ser interpretado como uma camada intermediária treinável dentro de uma arquitetura maior. Em problemas de classificação, o treinamento busca ajustar tanto parâmetros clássicos quanto parâmetros quânticos, minimizando uma função de perda associada aos rótulos verdadeiros (SCHETAKIS et al., 2022; LONG et al., 2025; DAKA; BHATTACHARYYA, 2026).

2.7.2 Integração entre CNNs e circuitos quânticos

A integração entre CNNs e circuitos quânticos pode ocorrer de diferentes formas. Uma abordagem é utilizar a CNN como extratora de características e substituir parte das camadas densas finais por uma camada quântica variacional. Nesse caso, a CNN processa a imagem, reduz sua dimensionalidade e envia ao circuito quântico um vetor compacto de características.

Outra abordagem é utilizar camadas quanvolucionais, propostas por Henderson et al. (2020). Nessas camadas, regiões locais da imagem são processadas por circuitos quânticos, de forma análoga ao funcionamento de filtros convolucionais clássicos. Uma região local da imagem, representada por u_x, é codificada em um circuito quântico por uma função e:

$$i_x = e(u_x).$$

Em seguida, o circuito quântico q transforma esse estado:

$$o_x = q(i_x) = q(e(u_x)).$$

Por fim, uma função de decodificação d, baseada em medições, transforma a saída quântica em um valor clássico:

$$f_x = d(o_x) = d(q(e(u_x))).$$

A transformação completa pode ser representada por:

$$f_x = Q(u_x, e, q, d).$$

Esse valor f_x passa a compor um mapa de características, de forma semelhante à saída de um filtro convolucional clássico. A principal diferença é que a transformação local não é uma simples multiplicação por um kernel clássico, mas sim o resultado de uma codificação, uma evolução quântica e uma medição.

Essa ideia é interessante para imagens porque evita a necessidade de codificar a imagem inteira em um único circuito. Em vez disso, pequenas regiões locais são processadas separadamente, reduzindo a quantidade de qubits necessária. Essa característica torna as camadas quanvolucionais mais compatíveis com dispositivos NISQ. Entretanto, essa abordagem também pode ser computacionalmente custosa, pois o circuito precisa ser executado muitas vezes para processar todas as regiões da imagem.

Em *benchmarks* variados de visão computacional, o acoplamento em que um extrator convolucional clássico reduz a resolução espacial e entrega um vetor latente compacto a um circuito quântico parametrizado oferece um equilíbrio superior entre expressividade e viabilidade de simulação em lotes.

2.7.3 Limitações práticas de dimensionalidade e custo de simulação em visão computacional

A aplicação de modelos híbridos quântico-clássicos em conjuntos de dados de visão computacional apresenta desafios estruturais significativos. O primeiro desafio reside na discrepância entre a dimensão de entrada das imagens e o número de qubits viável em simuladores clássicos e dispositivos NISQ atuais. Mesmo imagens compactas de *benchmarks* padronizados possuem entre 784 valores de intensidade (em bases $28 \times 28 \times 1$, como MNIST, Fashion-MNIST, KMNIST e EMNIST) e 3.072 valores (em bases RGB $32 \times 32 \times 3$, como CIFAR-10, CIFAR-100, SVHN e GTSRB), chegando a 2.304 valores no FER2013 ($48 \times 48 \times 1$). Codificar diretamente milhares de atributos em amplitudes ou rotações individuais de qubits exige circuitos de largura ou profundidade proibitivas para o treinamento iterativo em lotes (OKADA et al., 2025).

Por conseguinte, arquiteturas híbridas viáveis dependem de um extrator convolucional clássico (*backbone*) para comprimir a imagem original em um vetor latente de baixa dimensão compatível com o número de qubits do circuito variacional, seguido de uma camada clássica de projeção para as K classes do problema. Essa redução dimensional atua como um gargalo de informação (*information bottleneck*): enquanto em problemas de 10 classes estruturadas a representação comprimida pode reter poder discriminativo suficiente, em problemas com alta granularidade de classes (como GTSRB com 43 classes ou CIFAR-100 com 100 classes) ou alta sobreposição visual (como FER2013), o gargalo quântico pode limitar a capacidade de separação do modelo. Além disso, o cálculo de gradientes quânticos (como via regra de deslocamento de parâmetros ou diferenciação adjunta em simuladores de vetor de estado) impõe um custo computacional por época substancialmente superior ao de camadas densas clássicas, tornando indispensável a medição conjunta de métricas preditivas e telemetria de tempo de execução (FAJ et al., 2023; CHEN et al., 2024).

2.8 Trabalhos correlatos

2.8.1 Benchmarks em visão computacional e avaliação multi-dataset

A consolidação de modelos de aprendizado profundo está intrinsecamente ligada à criação de *benchmarks* padronizados de imagens. Desde a introdução do conjunto MNIST para reconhecimento de dígitos manuscritos (LECUN; BENGIO; HINTON, 2015), a comunidade científica ressaltou a necessidade de avaliar arquiteturas em domínios progressivamente mais complexos, originando substitutos diretos como o Fashion-MNIST (voltado a artigos de vestuário) e o KMNIST (focado em caracteres cursivos japoneses), bem como extensões de maior cardinalidade como o EMNIST.

Paralelamente, a avaliação em imagens de cenários reais consolidou-se por meio de

bases como CIFAR-10 e CIFAR-100 para objetos naturais, SVHN para dígitos urbanos, GTSRB para reconhecimento de sinalização viária e FER2013 para análise de expressões faciais (SZELISKI, 2022). Estudos comparativos demonstram que o comportamento de uma arquitetura neural não é uniforme entre esses domínios: escolhas de hiperparâmetros que saturam o desempenho em bases monocromáticas de dígitos podem apresentar instabilidade ou sobreajuste severo em bases RGB ou desbalanceadas, justificando protocolos experimentais baseados em múltiplos *datasets*.

2.8.2 Aprendizado profundo, hiperparâmetros e eficiência computacional

O avanço das redes neurais convolucionais modernas envolve não apenas o desenho de blocos de extração de características (SZEGEDY et al., 2015; HE et al., 2016; ZHAO; ZHANG, 2024), mas também a compreensão sistemática de fatores de treinamento e implantação, como a escolha da função de ativação, a sensibilidade ao tamanho do lote (*batch size*) e a quantização numérica (GOODFELLOW; BENGIO; COURVILLE, 2016; ZANDIEH et al., 2025). Pesquisas empíricas apontam que a interação entre tamanho de lote, função de ativação e plataforma de hardware impacta diretamente tanto a qualidade final da generalização (Macro-F1) quanto o tempo de convergência e a latência de inferência, exigindo análises pareadas sob controle rigoroso de variáveis.

2.8.3 Computação quântica e modelos híbridos aplicados à classificação de imagens

No campo do Aprendizado de Máquina Quântico, a combinação de redes convolucionais clássicas com circuitos quânticos variacionais ou camadas quanvolucionais tem sido amplamente explorada como alternativa compatível com o regime NISQ (BIAMONTE et al., 2017; PRESKILL, 2018; HENDERSON et al., 2020; CEREZO et al., 2021). Trabalhos recentes, como os de Long et al. (2025) e Daka e Bhattacharyya (2026), demonstram que arquiteturas híbridas quântico-clássicas podem atingir resultados competitivos em tarefas de classificação visual quando avaliadas em cenários controlados.

Entretanto, revisões críticas da literatura apontam que grande parte dos estudos em QML ainda restringe sua validação a versões reduzidas ou binárias de um único conjunto de dados (tipicamente MNIST ou Fashion-MNIST), sem contrastar o desempenho em múltiplas bases de maior complexidade e sem reportar sistematicamente o *trade-off* entre métricas preditivas, custo de simulação e variações de hiperparâmetros (EGGINGER; SAKHNENKO; LORENZ, 2024; YAN et al., 2024; GUPTA et al., 2025).

2.9 Síntese da lacuna de pesquisa

A análise da literatura revela que, embora existam inúmeros estudos avaliando CNNs clássicas em *benchmarks* isolados e propostas iniciais de modelos híbridos quântico-clássicos em versões simplificadas de dígitos manuscritos, há uma carência de estudos comparativos padronizados, reprodutíveis e multi-dataset que avaliem, sob o mesmo protocolo de engenharia e telemetria, o comportamento de arquiteturas clássicas e híbridas ao longo de múltiplos domínios visuais (abrangendo nove bases com diferentes resoluções, canais e números de classes), cruzando métricas de qualidade preditiva (Macro-F1, paridade e resíduos por classe) com análises sistemáticas de funções de ativação, varredura de tamanho de lote (*batch sweep*), quantização e desempenho multiplataforma (Windows e macOS). Este trabalho preenche diretamente essa lacuna por meio do protocolo metodológico descrito no Capítulo 3.

3 Desenvolvimento

Neste capítulo, apresenta-se a solução metodológica e experimental proposta para o problema identificado e o cronograma de desenvolvimento do projeto ao longo do TCC.

3.1 Solução proposta

A solução proposta consiste em um estudo experimental comparativo entre duas abordagens de classificação supervisionada de imagens avaliadas ao longo de nove conjuntos de dados de visão computacional (MNIST, Fashion-MNIST, KMNIST, EMNIST, CIFAR-10, CIFAR-100, SVHN, GTSRB e FER2013): uma abordagem clássica, baseada em redes neurais convolucionais (CNNs), e uma abordagem híbrida quântico-clássica baseada em circuitos quânticos parametrizados (PQCs) acoplados a um extrator convolucional clássico. O objetivo é estabelecer um protocolo padronizado, auditável e reprodutível de comparação entre modelos clássicos e híbridos sob condições experimentais estritamente equivalentes.

Em termos de arquitetura geral, o projeto contempla: (i) inventário e preparação padronizada das nove bases de dados; (ii) implementação e otimização do *baseline* clássico (incluindo estudos de funções de ativação, tamanhos de lote e quantização); (iii) implementação do modelo híbrido quântico-clássico; (iv) treinamento, validação e teste com as mesmas partições estratificadas e sementes aleatórias; e (v) análise quantitativa de desempenho preditivo (Macro-F1, acurácia, precisão, revocação e matrizes de confusão) e de telemetria computacional entre plataformas (Windows e macOS). Utiliza-se Python como linguagem principal, com PyTorch para aprendizado profundo clássico e bibliotecas de simulação de circuitos quânticos parametrizados para a camada híbrida.

Do ponto de vista metodológico, a pesquisa é conduzida como um estudo experimental comparativo com suporte teórico. Essa escolha justifica-se porque o objetivo central do TCC é implementar, controlar variáveis, executar campanhas sistemáticas de treinamento e comparar empiricamente os dois paradigmas. O foco da validação reside em métricas objetivas por classe e globais, varredura controlada de hiperparâmetros e registro completo de telemetria e ambiente computacional.

A pergunta de pesquisa que orienta a solução pode ser formulada da seguinte forma: *em tarefas de classificação supervisionada de imagens ao longo de múltiplos benchmarks de visão computacional com diferentes resoluções, canais e números de classes, arquiteturas híbridas quântico-clássicas apresentam convergência estável e desempenho competitivo em relação a CNNs clássicas quando avaliadas sob o mesmo protocolo experimental, e como escolhas de funções de ativação, tamanho de lote e quantização impactam a eficiência e a qualidade preditiva desses modelos?*

A hipótese de trabalho é que modelos híbridos podem alcançar convergência estável e desempenho competitivo em relação ao *baseline* clássico especialmente em bases de menor cardinalidade de classes, porém enfrentam limitações práticas decorrentes do gargalo de compressão dimensional para poucos qubits e do elevado custo de simulação quântica à medida que a complexidade visual e o número de classes aumentam. Dessa forma, o sucesso da pesquisa baseia-se na produção de evidências empíricas reprodutíveis que delimitem com rigor as condições de viabilidade, paridade e custo-benefício de cada abordagem.

Plano de validação

A validação da proposta é realizada por meio de: separação estratificada padronizada entre treino, validação e teste nas nove bases; controle estrito de sementes aleatórias; comparação pareada com o *baseline* clássico; avaliação por métricas globais e por classe (com destaque para Macro-F1 e resíduos ΔF1); análise de telemetria de tempo por época, *speedup*, *throughput* e latência; e discussão crítica das limitações observadas.

Riscos e limitações iniciais

Entre os riscos e desafios técnicos estão a heterogeneidade de resoluções e canais entre as nove bases, o forte desbalanceamento em conjuntos de cenários reais (como GTSRB, FER2013 e SVHN), o elevado custo computacional da simulação de circuitos quânticos variacionais e diferenças de desempenho entre plataformas de hardware. Como mitigação, o trabalho adota um *pipeline* unificado de configuração e pré-processamento, arquiteturas modularizadas, registro automatizado de métricas e telemetria e escopo estritamente focado em simulação reprodutível.

3.2 Tipo de pesquisa

3.3 Visão geral da solução proposta

3.4 Bases de dados e definição das classes

3.5 Pré-processamento e preparação dos dados

3.6 Modelo clássico de referência

3.7 Modelo híbrido quântico-clássico

3.8 Diagnóstico e evolução do modelo quântico

3.9 Protocolo experimental

3.9.1 Configuração dos experimentos

3.9.2 Controle de variáveis

3.9.3 Ambiente computacional (Windows e macOS)

3.9.4 Reprodutibilidade

3.10 Métricas de avaliação

3.11 Critérios de validação

3.12 Riscos e limitações

3.13 Cronograma

Tabela 2 – Cronograma de desenvolvimento do TCC.

Atividade	**Mês 1**	**Mês 2**	**Mês 3**	**Mês 4**
Revisão e ajuste da fundamentação teórica	X			
Inventário e padronização das 9 bases de dados	X			
Pré-processamento e *pipeline* experimental	X	X		
Implementação e experimentos da CNN clássica (ativações, *batch* e quantização)		X	X	
Implementação e treinamento do modelo híbrido quântico-clássico		X	X	
Consolidação de métricas, paridade e telemetria multiplataforma			X	X
Análise crítica dos resultados e redação final do TCC				X

Fonte: Elaborado pelo autor (2026).

Referências

BIAMONTE, J. et al. Quantum machine learning. *Nature*, v. 549, p. 195–202, 2017. 41, 50

CEREZO, M. et al. Variational quantum algorithms. *Nature Reviews Physics*, v. 3, p. 625–644, 2021. 11, 41, 43, 45, 50

CHEN, K.-C. et al. Quantum-classical-quantum workflow in quantum-hpc middleware with gpu acceleration. In: *2024 International Conference on Quantum Communications, Networking, and Computing (QCNC)*. [S.l.: s.n.], 2024. 49

DAKA, C.; BHATTACHARYYA, S. A novel quantum convolutional neural network framework for quantum-enhanced classification of pixelated colour images. *Scientific Reports*, v. 16, p. 10828, 2026. 47, 50

DEISENROTH, M. P.; FAISAL, A. A.; ONG, C. S. *Mathematics for Machine Learning*. Cambridge: Cambridge University Press, 2020. Disponível em: <https://mml-book.github.io/>. 22, 24, 26, 29, 30, 32

EGGINGER, S.; SAKHNENKO, A.; LORENZ, J. M. *A Hyperparameter Study for Quantum Kernel Methods*. 2024. 50

FAJ, J. et al. Quantum computer simulations at warp speed: Assessing the impact of gpu acceleration. a case study with ibm qiskit aer, nvidia thrust and cuquantum. In: *2023 IEEE 19th International Conference on e-Science (e-Science)*. [S.l.: s.n.], 2023. 49

FAWCETT, T. An introduction to roc analysis. *Pattern Recognition Letters*, v. 27, n. 8, p. 861–874, 2006. 29

GONZALEZ, R. C.; WOODS, R. E. *Digital Image Processing*. 3. ed. Upper Saddle River, NJ: Prentice Hall, 2008. 19

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. Cambridge, MA: MIT Press, 2016. Disponível em: <https://www.deeplearningbook.org/>. 24, 25, 30, 38, 39, 50

GUPTA, R. S. et al. A systematic review of quantum machine learning for digital health. *npj Digital Medicine*, v. 8, p. 237, 2025. 50

HAND, D. J.; TILL, R. J. A simple generalisation of the area under the roc curve for multiple class classification problems. *Machine Learning*, v. 45, p. 171–186, 2001. 29

HAVLÍČEK, V. et al. Supervised learning with quantum-enhanced feature spaces. *Nature*, v. 567, p. 209–212, 2019. 44

HE, K. et al. Deep residual learning for image recognition. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. [S.l.: s.n.], 2016. p. 770–778. 36, 50

HENDERSON, M. et al. Quanvolutional neural networks: Powering image recognition with quantum circuits. *Quantum Machine Intelligence*, v. 2, p. 2, 2020. 48, 50

HESARAKI, S. *Feature Map*. 2023. Medium. Disponível em: <https://medium.com/@saba99/feature-map-35ba7e6c689e>. Acesso em: 8 maio 2026. 36

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. *Nature*, v. 521, n. 7553, p. 436–444, 2015. 11, 15, 19, 30, 49

LONG, C. et al. Hybrid quantum-classical-quantum convolutional neural networks. *Scientific Reports*, v. 15, p. 31780, 2025. 11, 47, 50

MCCLEAN, J. R. et al. Barren plateaus in quantum neural network training landscapes. *Nature Communications*, v. 9, p. 4812, 2018. 46

NIELSEN, M. A.; CHUANG, I. L. *Quantum Computation and Quantum Information*. 10th anniversary edition. ed. Cambridge: Cambridge University Press, 2010. 40

OKADA, K. et al. Theoretical and numerical analysis of measurement limits in quantum image representations: Qubit lattice, frqi, and neqr. In: *2025 International Conference on Visual Communications and Image Processing (VCIP)*. [S.l.: s.n.], 2025. 49

PÉREZ-SALINAS, A. et al. Data re-uploading for a universal quantum classifier. *Quantum*, v. 4, p. 226, 2020. 44

PRESKILL, J. Quantum computing in the nisq era and beyond. *Quantum*, v. 2, p. 79, 2018. 41, 50

SCHETAKIS, N. et al. Review of some existing qml frameworks and novel hybrid classical-quantum neural networks realising binary classification for the noisy datasets. *Scientific Reports*, v. 12, p. 11927, 2022. 47

SCHULD, M.; SWEKE, R.; MEYER, J. J. Effect of data encoding on the expressive power of variational quantum-machine-learning models. *Physical Review A*, v. 103, n. 3, p. 032430, 2021. 43

SELVARAJU, R. R. et al. Grad-cam: Visual explanations from deep networks via gradient-based localization. *International Journal of Computer Vision*, v. 128, p. 336–359, 2020. 40

SILVA, K. F. C. d. *Impacto das técnicas de equilíbrio de classes na privacidade: uma análise dos ataques de inferência de associação*. Dissertação (Mestrado) — Universidade Federal do Maranhão, São Luís, MA, 2025. Disponível em: <https://tedebc.ufma.br/jspui/handle/tede/6610>. 19

SZEGEDY, C. et al. Going deeper with convolutions. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. [S.l.: s.n.], 2015. p. 1–9. 36, 50

SZELISKI, R. *Computer Vision: Algorithms and Applications*. 2. ed. Cham: Springer, 2022. 50

YAN, F. et al. Review of medical image processing using quantum-enabled algorithms. *Artificial Intelligence Review*, v. 57, n. 11, p. 1–52, 2024. 50

ZANDIEH, A. et al. *TurboQuant: Online Vector Quantization with Near-optimal Distortion Rate*. 2025. 38, 50

ZHAO, L.; ZHANG, Z. A improved pooling method for convolutional neural networks. *Scientific Reports*, v. 14, p. 1589, 2024. 34, 35, 50