Matheus Sanchez Duda

Classificação de câncer de mama em mamografias: um estudo comparativo entre CNNs clássicas e híbridas quântico-clássicas

São Paulo
2026

Matheus Sanchez Duda

Classificação de câncer de mama em mamografias: um estudo comparativo entre CNNs clássicas e híbridas quântico-clássicas

Proposta de Trabalho de Conclusão de Curso apresentada ao SENAC Santo Amaro como requisito parcial para aprovação na disciplina de TCC1 do curso de Ciência da Computação.

SENAC – Serviço Nacional de Aprendizagem Comercial
Unidade Santo Amaro
Bacharelado em Ciência da Computação

Orientador: Prof. Jorge Echeimberg
Coorientador: Prof. Thyago Quintas

São Paulo
2026

Resumo

Este trabalho tem o objetivo de aprimorar a arquitetura de redes neurais convolucionais feita anteriormente, que conseguia classificar imagens de cancer de mama em três classes (normal, benigna, maligna) com uma precisao de cerca de 70 por cento na media para as três classes. Agora deve ser feito a melhoria nos dois tipos de modelos para o classico conseguir clasificar mais exames radiograficos, e do modelo quântico poder ter resultados além do chute aleatório permitindo uma comparação mais robusta entre os dois tipos de modelos. **Palavras-chave**: câncer de mama. mamografia. redes neurais convolucionais.

computação quântica. aprendizado de máquina quântico.

Sumário

1 INTRODUÇÃO . . . 6
1.1 Contexto . . . 6
1.2 Problema de pesquisa . . . 6
1.3 Justificativa . . . 6
1.4 Pergunta de pesquisa . . . 6
1.5 Objetivo geral . . . 6
1.6 Objetivos específicos . . . 6
1.7 Hipótese ou pressuposto de pesquisa . . . 6
1.8 Delimitações do trabalho . . . 6

2 REVISÃO BIBLIOGRÁFICA . . . 7
2.1 Metodologia da pesquisa bibliográfica . . . 7
2.2 Câncer de mama, mamografia e classificação diagnóstica . . . 8
2.2.1 Mamografia e análise de imagens médicas . . . 9
2.2.2 Bases de dados em mamografia . . . 10
2.2.3 Mammo-Bench . . . 11
2.2.4 Qualidade dos rótulos, balanceamento e viés dos dados . . . 15
2.3 Imagens digitais e classificação computacional . . . 15
2.3.1 Representação de imagens digitais . . . 15
2.3.2 Pixels, matrizes e canais . . . 15
2.4 Fundamentos matemáticos e estatísticos . . . 15
2.4.1 Vetores, matrizes e tensores . . . 15
2.4.2 Probabilidade e estatística básica . . . 15
2.4.3 Métricas descritivas e análise de desempenho . . . 15
2.5 Aprendizado de máquina . . . 15
2.5.1 Aprendizado supervisionado . . . 15
2.5.2 Dados, rótulos e classes . . . 15
2.5.3 Treinamento, validação e teste . . . 15
2.5.4 Generalização, overfitting e underfitting . . . 15
2.5.5 Desbalanceamento de classes . . . 15
2.6 Redes neurais e aprendizado profundo . . . 15
2.6.1 Neurônio artificial, pesos e camadas . . . 15
2.6.2 Funções de ativação . . . 15
2.6.3 Função de perda e cálculo do erro . . . 15
2.6.4 Gradiente e otimização . . . 15

2.6.5 Regularização e early stopping . . . 15
2.7 Redes neurais convolucionais em mamografia . . . 15
2.7.1 Convolução, filtros e mapas de características . . . 15
2.7.2 Pooling e extração hierárquica de padrões . . . 15
2.7.3 Aumento de dados . . . 15
2.7.4 CNNs aplicadas à classificação de mamografias . . . 15
2.7.5 Explicabilidade e Grad-CAM . . . 15
2.8 Fundamentos de computação quântica . . . 15
2.8.1 Qubits . . . 15
2.8.2 Superposição, emaranhamento e medição . . . 15
2.8.3 Portas e circuitos quânticos . . . 15
2.8.4 Circuitos quânticos parametrizados . . . 15
2.9 Aprendizado de máquina quântico . . . 15
2.9.1 Codificação de dados clássicos em estados quânticos . . . 15
2.9.2 Feature maps . . . 15
2.9.3 Data re-uploading . . . 15
2.9.4 Modelos variacionais quânticos . . . 15
2.9.5 Barren plateaus e dificuldades de otimização . . . 15
2.9.6 Simulação quântica e limitações computacionais . . . 15
2.10 Modelos híbridos quântico-clássicos . . . 15
2.10.1 Arquiteturas híbridas para classificação . . . 15
2.10.2 Integração entre CNN e circuito quântico . . . 15
2.10.3 Limitações práticas em imagens de alta dimensão . . . 15
2.11 Trabalhos relacionados . . . 15
2.12 Síntese da lacuna de pesquisa . . . 15

3 DESENVOLVIMENTO: PROPOSTA METODOLÓGICA . . . 16
3.1 Tipo de pesquisa . . . 16
3.2 Visão geral da solução proposta . . . 16
3.3 Base de dados e definição das classes . . . 16
3.4 Pré-processamento e preparação dos dados . . . 16
3.5 Modelo clássico de referência . . . 16
3.6 Modelo híbrido quântico-clássico . . . 16
3.7 Diagnóstico do modelo quântico anterior . . . 16
3.8 Protocolo experimental . . . 16
3.8.1 Configuração dos experimentos . . . 16
3.8.2 Controle de variáveis . . . 16
3.8.3 Ambiente computacional . . . 16
3.8.4 Reprodutibilidade . . . 16

3.9 Métricas de avaliação 16
3.10 Critérios de validação 16
3.11 Riscos e limitações 16
3.12 Cronograma 16

REFERÊNCIAS 18

1 Introdução

1.1 Contexto

1.2 Problema de pesquisa

1.3 Justificativa

1.4 Pergunta de pesquisa

1.5 Objetivo geral

1.6 Objetivos específicos

1. Definir a base de dados e as classes diagnósticas utilizadas no experimento;
2. Preparar um protocolo padronizado de pré-processamento, divisão dos dados, treinamento, validação e teste;
3. Aprimorar uma CNN clássica para servir como modelo de referência;
4. Projetar uma arquitetura híbrida quântico-clássica compatível com as limitações de simulação disponíveis;
5. Investigar configurações do modelo híbrido, como número de qubits, feature map, profundidade do circuito e estratégia de codificação;
6. Comparar os modelos por meio de métricas como acurácia, precisão, recall, F1-score, AUC e matriz de confusão;
7. Avaliar tempo de treinamento, uso de memória, estabilidade entre execuções e limitações de escalabilidade;
8. Discutir criticamente as vantagens, limitações e condições de viabilidade da abordagem híbrida quântico-clássica.

1.7 Hipótese ou pressuposto de pesquisa

1.8 Delimitações do trabalho

2 Revisão Bibliográfica

2.1 Metodologia da pesquisa bibliográfica

A pesquisa bibliográfica deste trabalho será conduzida com o objetivo de fundamentar teoricamente e metodologicamente o estudo comparativo entre redes neurais convolucionais clássicas e modelos híbridos quântico-clássicos aplicados à classificação de câncer de mama em imagens de mamografia.

As buscas serão realizadas em bases científicas nacionais e internacionais, incluindo Google Scholar, PubMed, IEEE Xplore, ACM Digital Library, Scopus, SciELO e Periódicos CAPES. A escolha dessas bases se justifica pela abrangência de publicações nas áreas de Ciência da Computação, Inteligência Artificial, visão computacional, imagens médicas, radiologia e computação quântica. Também poderão ser consultados repositórios de pré-publicações, como arXiv, medRxiv e bioRxiv, quando o trabalho apresentar relevância direta para o tema, especialmente em tópicos recentes ainda em consolidação.

Serão utilizadas palavras-chave em português e inglês, combinadas por meio de operadores booleanos. Entre os principais termos estão: *"câncer de mama"*, *"mamografia"*, *"classificação de imagens médicas"*, *"redes neurais convolucionais"*, *"aprendizado profundo"*, *"computação quântica"*, *"aprendizado de máquina quântico"*, *"modelos híbridos quântico-clássicos"*, *"breast cancer"*, *"mammography"*, *"mammogram"*, *"convolutional neural network"*, *"deep learning"*, *"medical image classification"*, *"quantum machine learning"*, *"quantum neural network"*, *"variational quantum circuit"* e *"hybrid quantum-classical neural network"*.

As strings de busca serão organizadas em blocos temáticos. O primeiro bloco contemplará estudos sobre classificação de câncer de mama em mamografias com redes neurais convolucionais e aprendizado profundo. O segundo abordará detecção, segmentação, regiões de interesse, microcalcificações e massas mamárias. O terceiro tratará de bases de dados e benchmarks públicos de mamografia, como DDSM, CBIS-DDSM, INbreast, CMMD, VinDr-Mammo, CDD-CESM, DMID, RSNA e Mammo-Bench. O quarto bloco reunirá estudos sobre robustez, validação externa, generalização e reprodutibilidade de modelos de aprendizado profundo em mamografia. O quinto bloco contemplará artigos relacionados à explicabilidade, Grad-CAM, aprendizado baseado em patches, curriculum learning e uso de anotações fracas ou fortes. Por fim, o sexto bloco reunirá trabalhos sobre aprendizado de máquina quântico, redes neurais quânticas, classificadores variacionais, métodos de kernel quântico e arquiteturas híbridas quântico-clássicas.

Como critérios de inclusão, serão priorizados trabalhos publicados entre 2021 e 2026, em português ou inglês, que abordem diretamente classificação de câncer de mama,

mamografia, visão computacional médica, aprendizado profundo aplicado a imagens médicas ou modelos híbridos quântico-clássicos aplicados a tarefas de classificação. Também serão incluídos artigos sobre bases de dados amplas, benchmarks, validação externa, classificação multiclasse e estratégias de generalização, desde que contribuam para o desenvolvimento metodológico do TCC. Além disso, serão considerados artigos seminais anteriores a 2021, quando forem essenciais para a fundamentação teórica, como estudos clássicos sobre redes neurais convolucionais, arquiteturas profundas e aplicações pioneiras de aprendizado profundo em mamografia.

A seleção dos artigos será realizada em etapas. Inicialmente, serão analisados título, resumo e palavras-chave para verificar a aderência ao tema. Em seguida, os trabalhos potencialmente relevantes serão avaliados quanto ao objetivo, base de dados utilizada, tipo de imagem, número de classes, arquitetura proposta, métricas de avaliação, estratégia de validação, resultados obtidos e limitações declaradas. Os artigos selecionados serão organizados em uma matriz de revisão bibliográfica, contendo informações como ano, autores, título, base de dados, método, tarefa abordada, métricas, principais contribuições e relação com a proposta do TCC.

A análise dos trabalhos buscará identificar convergências e divergências entre os estudos, com atenção especial a aspectos como desempenho preditivo, uso de bases públicas, tratamento de desbalanceamento, validação externa, explicabilidade, custo computacional e limitações de generalização. No caso dos modelos quânticos e híbridos quântico-clássicos, também serão observados aspectos como número de qubits, tipo de codificação dos dados, circuito variacional, simulador ou hardware utilizado, escalabilidade e comparação com modelos clássicos.

Dessa forma, a pesquisa bibliográfica não terá apenas a finalidade de reunir referências, mas de posicionar criticamente a proposta deste trabalho. A revisão permitirá justificar a escolha da mamografia como domínio de aplicação, a adoção de CNNs como base clássica de comparação, a investigação de modelos híbridos quântico-clássicos como alternativa experimental e a necessidade de um protocolo controlado, reprodutível e comparativo para avaliar desempenho, custo computacional e viabilidade prática.

2.2 Câncer de mama, mamografia e classificação diagnóstica

O câncer de mama é uma das doenças oncológicas de maior impacto na saúde pública, especialmente devido à sua alta incidência e à importância do diagnóstico precoce para o aumento das chances de tratamento bem-sucedido. Nesse contexto, a mamografia é amplamente utilizada como exame de rastreamento, pois permite a identificação de alterações suspeitas no tecido mamário antes mesmo do surgimento de sintomas clínicos evidentes.

A mamografia consiste em um exame de imagem baseado em raios X, utilizado para visualizar a estrutura interna da mama. A partir dessas imagens, radiologistas analisam a presença de achados como massas, calcificações, assimetrias e distorções arquiteturais. Massas podem aparecer como regiões mais densas, com diferentes formatos e margens; calcificações correspondem a pequenos depósitos de cálcio; assimetrias representam diferenças entre regiões correspondentes das mamas; e distorções arquiteturais indicam alterações na organização normal do tecido mamário. Esses achados podem estar associados a condições benignas ou malignas, exigindo interpretação especializada.

Do ponto de vista clínico, a classificação diagnóstica busca organizar os exames conforme o grau de suspeita ou o tipo de condição observada. Em bases de dados de mamografia, é comum encontrar rótulos como *Normal*, *Benign*, *Suspicious Malignant* e *Malignant*. A classe *Normal* representa exames sem achados relevantes; *Benign* indica alterações não cancerígenas; *Suspicious Malignant* representa casos suspeitos que exigem investigação adicional; e *Malignant* corresponde a achados associados ao câncer de mama.

Além dessas classes, muitos conjuntos de dados também utilizam o sistema BI-RADS (*Breast Imaging Reporting and Data System*), uma padronização empregada por radiologistas para classificar os achados em exames de mama. Esse sistema varia de 0 a 6, incluindo desde exames inconclusivos até casos com malignidade comprovada por biópsia. No contexto computacional, esses rótulos podem ser utilizados como base para tarefas de classificação automática, transformando o problema clínico em um problema de aprendizado supervisionado.

Neste trabalho, o problema é delimitado como uma tarefa de classificação de imagens mamográficas em classes diagnósticas. O objetivo não é substituir a avaliação médica, mas investigar o desempenho de modelos computacionais capazes de reconhecer padrões visuais associados às classes *Normal*, *Benign* e *Malignant*. Essa formulação permite comparar diferentes arquiteturas de aprendizado de máquina sob as mesmas condições experimentais, contribuindo para a análise do potencial de modelos clássicos e híbridos quântico-clássicos na classificação de mamografias.

2.2.1 Mamografia e análise de imagens médicas

A análise computacional de mamografias apresenta desafios específicos quando comparada à análise de imagens naturais. Em geral, as mamografias são imagens de alta resolução, em escala de cinza, nas quais pequenas regiões podem conter informações clinicamente relevantes. Lesões iniciais podem ocupar uma área reduzida da imagem, apresentar baixo contraste em relação ao tecido ao redor ou ser parcialmente ocultadas por tecidos densos. Dessa forma, a classificação automática exige modelos capazes de identificar padrões sutis e espacialmente distribuídos.

A aquisição da mamografia normalmente envolve diferentes projeções da mama. As duas

vistas mais comuns são a craniocaudal (CC), obtida de cima para baixo, e a mediolateral oblíqua (MLO), obtida em uma posição angulada. Essas projeções fornecem informações complementares sobre o tecido mamário e são frequentemente utilizadas em conjunto na prática clínica. Em muitos conjuntos de dados, cada exame pode conter imagens da mama esquerda e direita nessas duas vistas, formando um conjunto de quatro imagens por paciente.

Outro aspecto importante é a variabilidade entre imagens. Mamografias podem variar conforme o equipamento utilizado, o protocolo de aquisição, a compressão aplicada, a densidade mamária, a idade da paciente, a presença de implantes, a qualidade do pré-processamento e o formato original do arquivo. Além disso, bases públicas podem reunir imagens de diferentes instituições e países, o que aumenta a diversidade dos dados, mas também introduz variações de domínio que podem influenciar o treinamento dos modelos.

Esses fatores tornam a análise de imagens médicas uma tarefa sensível. Um modelo pode apresentar bom desempenho em uma base específica, mas ter dificuldade de generalização quando aplicado a imagens de outra origem. Por isso, técnicas de pré-processamento, normalização, balanceamento de classes e separação adequada entre treino, validação e teste são essenciais para reduzir vieses e produzir resultados mais confiáveis.

As redes neurais convolucionais são amplamente utilizadas nesse tipo de problema porque conseguem extrair automaticamente características espaciais das imagens, como bordas, texturas, formas e padrões locais. Em mamografias, essas características podem estar associadas a massas, calcificações ou alterações estruturais do tecido. Entretanto, devido à complexidade clínica do exame, o uso de modelos computacionais deve ser interpretado como ferramenta de apoio à análise, e não como substituto da decisão médica.

2.2.2 Bases de dados em mamografia

As bases de dados de mamografia são fundamentais para o desenvolvimento, treinamento e avaliação de modelos computacionais aplicados à classificação e detecção do câncer de mama. A disponibilidade de conjuntos públicos permite que diferentes trabalhos comparem métodos sob condições semelhantes, além de favorecer a reprodutibilidade científica. Entretanto, bases de mamografia frequentemente apresentam limitações relacionadas ao número de imagens, qualidade dos exames, formatos de arquivo, tipos de anotação e distribuição das classes.

Entre as bases públicas mais utilizadas na literatura estão DDSM, CBIS-DDSM, INbreast, MIAS, BCDR, CMMD, CDD-CESM, DMID, KAU-BCMD e RSNA Screening Mammography. Cada uma possui características próprias. Algumas são compostas por mamografias digitalizadas antigas, enquanto outras utilizam mamografia digital moderna. Algumas fornecem anotações detalhadas de regiões de interesse, enquanto outras disponibilizam apenas rótulos globais por imagem ou exame. Também existem diferenças na

presença de metadados, como idade da paciente, densidade mamária, BI-RADS, tipo de anormalidade e subtipo molecular.

Essas diferenças impactam diretamente o uso das bases em aprendizado de máquina. Bases pequenas podem dificultar o treinamento de modelos profundos; bases muito desbalanceadas podem favorecer a classe majoritária; e bases coletadas em uma única instituição podem limitar a generalização dos modelos. Além disso, a ausência de anotações locais, como máscaras ou regiões de interesse, dificulta tarefas de detecção e segmentação, restringindo muitos estudos à classificação global da imagem.

O Mammo-Bench foi proposto como um benchmark de larga escala para mamografias, reunindo dados de sete bases públicas: DDSM, INbreast, KAU-BCMD, CMMD, CDD-CESM, RSNA Screening Dataset e DMID. O conjunto foi construído com uma etapa de padronização e pré-processamento, incluindo conversão de formato, segmentação da mama, remoção do músculo peitoral e recorte inteligente, com o objetivo de reduzir diferenças entre as fontes e preservar regiões clinicamente relevantes. Segundo os autores, o Mammo-Bench reúne imagens de diferentes países e fornece anotações como classes diagnósticas, BI-RADS, densidade mamária, anormalidades e subtipos moleculares quando disponíveis.

No contexto deste trabalho, o Mammo-Bench é especialmente relevante por reunir um número maior de imagens do que muitas bases individuais e por permitir a formulação de uma tarefa de classificação em múltiplas classes. A partir dos arquivos analisados, é possível trabalhar com classes como *Normal*, *Benign* e *Malignant*, mantendo um recorte compatível com a proposta experimental. Ainda assim, é necessário considerar suas limitações, como o desbalanceamento entre classes, a predominância de determinadas bases de origem e a ausência de anotações locais para parte significativa das imagens.

2.2.3 Mammo-Bench

O Mammo-Bench é um conjunto de dados de larga escala voltado para pesquisas em mamografia e classificação de câncer de mama. Ele foi construído a partir da integração de diferentes bases públicas de mamografias, com o objetivo de reunir imagens provenientes de múltiplas fontes, instituições e populações, reduzindo algumas limitações comuns em bases isoladas, como baixo número de amostras, ausência de padronização, diferenças de formato e desbalanceamento entre classes.

Segundo a descrição original do conjunto, o Mammo-Bench reúne imagens mamográficas de 26.500 pacientes provenientes de sete países diferentes, a partir de bases como DDSM, INbreast, KAU-BCMD, CMMD, CDD-CESM, RSNA Screening Dataset e DMID (BHOLE; SUSEELA; PAREKH, 2025). Entretanto, na versão dos arquivos CSV analisados neste trabalho, foram encontradas 71.844 imagens, distribuídas entre sete bases de origem. Essa diferença ocorre porque a versão utilizada nos experimentos contém a base `mini-ddsm`, uma versão reduzida ou filtrada do DDSM original.

As imagens disponibilizadas na versão analisada estão referenciadas em formato `JPG`. Por se tratar de mamografias, as imagens são tratadas como imagens em escala de cinza, isto é, com apenas um canal de cor. Além disso, os arquivos CSV não informam diretamente as dimensões originais de cada imagem, pois o tamanho final de entrada é definido durante o pré-processamento experimental. Neste trabalho, as imagens são redimensionadas para o tamanho definido no pipeline de treinamento, preservando o mesmo padrão para todos os modelos avaliados.

A Tabela 1 apresenta a distribuição das imagens por base de origem na versão do Mammo-Bench utilizada neste trabalho.

Tabela 1 – Distribuição das imagens por base de origem no CSV do Mammo-Bench

Base no CSV	**Quantidade de imagens**	**Observação**
`rsna-screening`	54.705	Maior base do conjunto; muito desbalanceada
`mini-ddsm`	7.808	Versão reduzida/filtrada do DDSM
`cmmd`	5.202	Importante para subtipo molecular e anormalidad
`kau-bcmd`	2.206	Contém BI-RADS e densidade
`cdd-cesm`	1.003	Mamografia espectral com contraste
`dmid`	510	Pequena, com BI-RADS, densidade e anormalidad
`inbreast`	410	Pequena, mas bem anotada
Total	**71.844**	Versão dos CSVs enviados

Observa-se que a maior parte das imagens é proveniente da base `rsna-screening`, que representa 54.705 imagens do total analisado. Essa predominância é relevante do ponto de vista metodológico, pois pode introduzir viés de origem no treinamento dos modelos. Em outras palavras, um modelo pode aprender características associadas à base de dados, ao equipamento ou ao processo de aquisição, em vez de aprender exclusivamente padrões relacionados às alterações mamárias.

Além da diferença na quantidade de imagens por base, o Mammo-Bench também apresenta diferentes tipos de anotação. Entre elas, destacam-se as classes diagnósticas gerais, como *Normal*, *Benign*, *Suspicious Malignant* e *Malignant*; classificações BI-RADS; densidade mamária; tipo de anormalidade; e subtipo molecular, quando disponível. No entanto, nem todas as bases fornecem todos esses tipos de anotação, o que torna necessário definir um recorte específico para os experimentos.

No CSV principal, a distribuição das classes diagnósticas por base de origem é apresentada na Tabela 2.

Tabela 2 – Distribuição das classes por base de origem no CSV principal do Mammo-Bench

Base	**Normal**	**Benign**	**Suspicious Malignant**	**Malignant**	**Sem classe**	**To**
`rsna-screening`	24.021	2.265	0	0	28.419	54.
`mini-ddsm`	2.408	2.684	0	2.716	0	7.
`cmmd`	0	1.108	0	4.094	0	5.
`kau-bcmd`	1.847	265	72	22	0	2.
`cdd-cesm`	341	331	0	331	0	1.
`dmid`	212	154	120	24	0	
`inbreast`	67	243	43	57	0	

A partir da Tabela 2, é possível observar um forte desbalanceamento entre as classes. A classe *Normal* possui uma quantidade significativamente maior de imagens em comparação com as classes *Benign* e *Malignant*. Além disso, a base `rsna-screening` contém uma grande quantidade de imagens sem classe diagnóstica definida no CSV principal, representadas na coluna "Sem classe". Essas imagens não são adequadas para a tarefa de classificação supervisionada proposta, pois não possuem rótulo diagnóstico diretamente utilizável.

Neste trabalho, o Mammo-Bench é utilizado como base principal para a tarefa de classificação diagnóstica de mamografias. A análise inicial considera as classes *Normal*, *Benign*, *Suspicious Malignant* e *Malignant*, além das imagens sem classe diagnóstica definida no CSV principal. O detalhamento sobre a seleção das classes utilizadas no treinamento, o tratamento do desbalanceamento e os possíveis vieses dos dados é apresentado posteriormente na seção de qualidade dos rótulos, balanceamento e viés dos dados.

2.2.4 Qualidade dos rótulos, balanceamento e viés dos dados

2.3 Imagens digitais e classificação computacional

2.3.1 Representação de imagens digitais

2.3.2 Pixels, matrizes e canais

2.4 Fundamentos matemáticos e estatísticos

2.4.1 Vetores, matrizes e tensores

2.4.2 Probabilidade e estatística básica

2.4.3 Métricas descritivas e análise de desempenho

2.5 Aprendizado de máquina

2.5.1 Aprendizado supervisionado

2.5.2 Dados, rótulos e classes

2.5.3 Treinamento, validação e teste

2.5.4 Generalização, overfitting e underfitting

2.5.5 Desbalanceamento de classes

2.6 Redes neurais e aprendizado profundo

2.6.1 Neurônio artificial, pesos e camadas

2.6.2 Funções de ativação

2.6.3 Função de perda e cálculo do erro

2.6.4 Gradiente e otimização

2.6.5 Regularização e early stopping

2.7 Redes neurais convolucionais em mamografia

2.7.1 Convolução, filtros e mapas de características

2.7.2 Pooling e extração hierárquica de padrões

2.7.3 Aumento de dados

3 Desenvolvimento: proposta metodológica

3.1 Tipo de pesquisa

3.2 Visão geral da solução proposta

3.3 Base de dados e definição das classes

3.4 Pré-processamento e preparação dos dados

3.5 Modelo clássico de referência

3.6 Modelo híbrido quântico-clássico

3.7 Diagnóstico do modelo quântico anterior

3.8 Protocolo experimental

3.8.1 Configuração dos experimentos

3.8.2 Controle de variáveis

3.8.3 Ambiente computacional

3.8.4 Reprodutibilidade

3.9 Métricas de avaliação

3.10 Critérios de validação

3.11 Riscos e limitações

3.12 Cronograma

Tabela 3 – Cronograma preliminar de desenvolvimento do TCC

Atividade	**Mês 1**	**Mês 2**	**Mês 3**	**Mês 4**
Revisão e ajuste da fundamentação teórica	X			
Definição da base de dados e das classes	X			
Pré-processamento e organização dos dados	X	X		
Implementação e ajuste da CNN clássica		X		
Implementação do modelo híbrido quântico-clássico		X	X	
Execução dos experimentos comparativos			X	
Análise dos resultados e métricas			X	X
Redação final e revisão do TCC				X

Fonte: Elaborado pelo autor.

Referências

BHOLE, G.; SUSEELA, S.; PAREKH, N. Mammo-bench: A large-scale benchmark dataset of mammography images. *medRxiv*, 2025. 11